

Universidade Federal de São Carlos - UFSCar
Departamento de Computação - DC
CEP 13565-905, Rod. Washington Luiz, s/n, São Carlos, SP

Árvores de decisão


Prof. Dr. Alan Demétrius Baria Valejo


Aprendizado de Máquina


- Introdução
- ID3
- Vantagens e limitações
- Próxima aula

Introdução


- Didático.
- Explicabilidade do modelo.
- O estudante consegue visualizar o modelo ser construído e fazer o teste de mesa.
- Interpretabilidade.









- **Porque decisão?**
- Em uma árvore de decisão cada nó interno corresponde a um teste em um atributo, **cada ramificação representa a saída de um teste**, e **cada nó folha representa um rótulo de classe**.
- Abordagem *top-down*: da raiz para as folhas.




- Aprendizado **simbólico**, pois eles têm a capacidade de **descrever os padrões** extraídos da bases de dados em uma linguagem de **fácil compreensão** para os seres humanos.





<https://www.kaggle.com/uciml/pima-indians-diabetes-database>

ID	Tempo	Temperatura	Umidade	Vento	Classe
1	Ensolarado	Quente	Alta	Não	Não
2	Ensolarado	Quente	Alta	Sim	Não
3	Nublado	Quente	Alta	Não	Sim
4	Chuvoso	Médio	Alta	Não	Sim
5	Chuvoso	Frio	Normal	Não	Sim
6	Chuvoso	Frio	Normal	Sim	Não
7	Nublado	Frio	Normal	Sim	Sim
8	Ensolarado	Médio	Alta	Não	Não
9	Ensolarado	Frio	Normal	Não	Sim
10	Chuvoso	Médio	Normal	Não	Sim
11	Ensolarado	Médio	Normal	Sim	Sim
12	Nublado	Médio	Alta	Sim	Sim
13	Nublado	Quente	Normal	Não	Sim
14	Chuvoso	Médio	Alta	Sim	Não




Árvores de decisão

Atributos numéricos e nominais

ID	Tempo	Temperatura	Umidade	Vento	Classe
1	Ensolarado	Quente	Alta	Não	Não
2	Ensolarado	Quente	Alta	Sim	Não
3	Nublado	Quente	Alta	Não	Sim
4	Chuvoso	Médio	Alta	Não	Sim
5	Chuvoso	Frio	Normal	Não	Sim
6	Chuvoso	Frio	Normal	Sim	Não
7	Nublado	Frio	Normal	Sim	Sim
8	Ensolarado	Médio	Alta	Não	Não
9	Ensolarado	Frio	Normal	Não	Sim
10	Chuvoso	Médio	Normal	Não	Sim
11	Ensolarado	Médio	Normal	Sim	Sim
12	Nublado	Médio	Alta	Sim	Sim
13	Nublado	Quente	Normal	Não	Sim
14	Chuvoso	Médio	Alta	Sim	Não

- Considerando o conceito mais geral de árvore de decisão, é permitido tanto valores numéricos quanto valores nominais.
- Entretanto, o algoritmo responsável por induzir a árvore pode restringir-se para valores nominais ou numéricos.




Árvores de decisão



Atributos numéricos e nominais

ID	Tempo	Temperatura	Umidade	Vento	Classe
1	Ensolarado	85	85	Não	Não
2	Ensolarado	80	90	Sim	Não
3	Nublado	83	86	Não	Sim
4	Chuvoso	70	96	Não	Sim
5	Chuvoso	68	80	Não	Sim
6	Chuvoso	65	70	Sim	Não
7	Nublado	64	65	Sim	Sim
8	Ensolarado	72	95	Não	Não
9	Ensolarado	69	70	Não	Sim
10	Chuvoso	75	80	Não	Sim
11	Ensolarado	75	70	Sim	Sim
12	Nublado	72	90	Sim	Sim
13	Nublado	81	75	Não	Sim
14	Chuvoso	71	91	Sim	Não


- Considerando o conceito mais geral de árvore de decisão, é permitido tanto valores numéricos quanto valores nominais.
- Entretanto, o algoritmo responsável por induzir a árvore pode restringir-se para valores nominais ou numéricos.





- A algoritmo busca **dividir o espaço recursivamente** até **encontrar um espaço que seja mais homogêneos** (que possuem apenas exemplos de uma única classe). **Portanto, é um modelo não linear.**







LORENA, Ana Carolina;
GAMA, João; FACELI,
Katti. Inteligência Artificial:
Uma abordagem de
aprendizado de máquina.
Grupo Gen-LTC,






















- Pergunta: Para o problema anterior, somente aquela árvore de decisão seria possível?
- Ela é ótima?



- Pergunta: Para o problema anterior, somente aquela árvore de decisão seria possível?
- Ela é ótima?



- Pergunta: Para o problema anterior, somente aquela árvore de decisão seria possível?
- Ela é ótima?



- Os algoritmos tentam particionar o espaço de modo a selecionar primeiro os atributo com maior utilidade para a classificação.




Atributo que
melhor separa as
classes.



- Algoritmos para a indução de árvores de decisão:
 - ID3 (*Iterative Dechotomiser*) [Quinlan, 1986];
 - Usa a Entropia, Ganho de Informação e a Razão de ganho (*Gain Ratio*);
 - C4.5 (sucessor do ID3) [Quinlan, 1993];
 - Usa a Entropia, Ganho de Informação e a Razão de ganho (*Gain Ratio*);
 - Classification and Regresion Trees (CART) [Breiman et., 1984];
 - Usa o índice de Gini.

Induzir uma árvore é o processo
de selecionar e ranquear os
melhores atributos.

- Os algoritmos tentam particionar o espaço de modo a selecionar primeiro os atributo com maior utilidade para a classificação.



- Os algoritmos tentam particionar o espaço de modo a selecionar primeiro os atributo com maior utilidade para a classificação.





Atributo que
melhor separa as
classes.

- Algoritmos para a indução de árvores de decisão:
 - ID3 (*Iterative Dechotomiser*) [Quinlan, 1986];
 - Usa a Entropia, Ganho de Informação e a Razão de ganho (*Gain Ratio*);
 - C4.5 (sucessor do ID3) [Quinlan, 1993];
 - Usa a Entropia, Ganho de Informação e a Razão de ganho (*Gain Ratio*);
 - Classification and Regresion Trees (CART) [Breiman et., 1984];
 - Usa o índice de Gini.

Induzir uma árvore é o processo
de selecionar e ranquear os
melhores atributos.

- Os algoritmos tentam particionar o espaço de modo a selecionar primeiro os atributo com maior utilidade para a classificação



- Algoritmos para a indução de árvores de decisão:
 - ID3 (*Iterative Dechotomiser*) [Quinlan, 1986];
 - Usa a Entropia, Ganho de Informação e a Razão de ganho (*Gain Ratio*);
 - C4.5 (sucessor do ID3) [Quinlan, 1993];
 - Usa a Entropia, Ganho de Informação e a Razão de ganho (*Gain Ratio*);
 - Classification and Regresion Trees (CART) [Breiman et., 1984];
 - Usa o índice de Gini.
- Partições mais puras.
 - Selecionar atributos que dividem melhor o espaço.
 - Atributos úteis.

- ID3 (*Iterative Dichotomiser 3*):
 - Artigo original:
 - Quinlan, J. R. (1986);
 - “*Induction of Decision Trees*”;
 - Machine Learning, 1(1), 81–106;
 - <https://doi.org/10.1007/BF00116251>;
 - Resumo: Este artigo introduziu o ID3 e a ideia de construir árvores com base no ganho de informação, usando a entropia de Shannon.

↑ Utilidade

=

↑ Ganho de informação

↑ Utilidade

=

↑ Ganho de informação

- Como eu calculo o ganho de informação?

A Entropia mede o grau de desordem de um conjunto.

$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

O somatório negativo das probabilidades dos elementos de cada classe multiplicadas pelo logaritmo dessas probabilidades.

↑ Entropia

=

↑ Desordem ou baixa pureza

↓ Entropia

=

↓ Desordem ou alta pureza

$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

↑ Entropia

=

↑ Desordem ou baixa pureza

↓ Entropia

=

↓ Desordem ou alta pureza

- O que é melhor?

$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

↑ Entropia

=

↑ Desordem ou baixa pureza

↓ Entropia

=

↓ Desordem ou alta pureza

- O que é melhor?


Dado um conjunto de exemplos, qual atributo escolher para realizar a partição?

- Entropia é uma **medida do grau de aleatoriedade ou desordem ou mistura** (grau de pureza de um atributo) de um conjunto.
- A entropia de um atributo qualitativo X_i (ou variável nominal), com instâncias pertencentes à classe i , é dada por:


- A cada iteração o meu conjunto $|D|$ diminui.

$$Entropia(D[X_i]) = - \sum_{i=1}^k p_i \log_2 p_i$$

em que D é nosso conjunto de treinamento e $C = \{c_1, c_2, \dots, c_k\}$ o conjunto de classes com k classes; $|D|$ é a quantidade de exemplos no conjunto de treinamento; $|c_i|$ é a quantidade de exemplos da classe c_i em D e **p_i é a probabilidade de cada classe c_i ocorrer em D (ou proporção de elementos da classe c_i ocorrer em $D[X_i]$)**, ou seja, **$|c_i|/|D|$** . Dado que $\log_a 0$ é indefinido, consideramos $0 \times \log_a 0 = 0$.



$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$




$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

$$Entropia(D) = -\frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14} = 0,940$$

• Classe verde

• Classe vermelha



↑ Entropia

=

↑ Desordem ou baixa pureza

↓ Entropia

=


↓ Desordem ou alta pureza

$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$


$$Entropia(D) = - \frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14} = 0,940$$

• Classe verde

• Classe vermelha




$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$



$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$


$$Entropia(D) = -\frac{9}{10} \log_2 \frac{9}{10} - \frac{1}{10} \log_2 \frac{1}{10} = 0,467$$



- Importante:
 - Essa é a entropia de todo o conjunto;
 - Entropia do Pai.

$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

$$Entropia(D) = - \frac{9}{10} \log_2 \frac{9}{10} - \frac{1}{10} \log_2 \frac{1}{10} = 0,467$$




$$Entropia(D_a) = - \sum_{i=1}^k p_i \log_2 p_i$$

$$Entropia(D_b) = - \sum_{i=1}^k p_i \log_2 p_i$$

- Importante:
 - Essa é a entropia do conjunto particionado;
 - Entropia dos filhos.

$$Entropia(D_a) = - \sum_{i=1}^k p_i \log_2 p_i$$



$$Entropia(D_b) = - \sum_{i=1}^k p_i \log_2 p_i$$



- Importante:
 - Essa é a entropia do conjunto particionado;
 - Entropia dos filhos.

$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

$$Entropia(D_a) = - \sum_{i=1}^k p_i \log_2 p_i$$

$$Entropia(D_b) = - \sum_{i=1}^k p_i \log_2 p_i$$

- Qual é a maior entropia?
- Do pai ou dos filhos?
- Com corte ou sem corte?



- Qual é a maior entropia?
- Do pai ou dos filhos?
- Com corte ou sem corte?

$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

↑ Ganho de informação

=

↓ Entropia

↓ Ganho de informação

=

↑ Entropia


- Ganho de Informação:
 - O ganho de informação mede a redução da entropia causada pela partição dos exemplos de acordo com os valores do atributo.

$$GI(D, A) = Entropia_{Pai} - \sum_{j=1}^m Peso_{Filho} Entropia_{Filho}$$

em que $A = \{1, \dots, m\}$ é um atributo com m valores possíveis.



$$Entropia(D) = - \sum_{i=1}^k p_i \log_2 p_i$$



- Ganho de Informação:
 - O ganho de informação mede a redução da entropia causada pela partição dos exemplos de acordo com os valores do atributo.

$$GI(D, A) = Entropia_{Pai} - \sum_{j=1}^m Peso_{Filho} Entropia_{Filho}$$

$$GI(D, A) = Entropia(D) - \sum_{j=1}^m \frac{|X_j|}{|D|} Entropia(X_j)$$

em que $X = \{1, \dots, m\}$ é um atributo com m valores possíveis.

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não

Nó Pai: Conjunto D

$$p_{Sim} = \frac{3}{6} = \frac{1}{2} \quad p_{Não} = \frac{3}{6} = \frac{1}{2}$$

$$Entropia(D) = -(p_{Sim} \log_2 p_{Sim} + p_{Não} \log_2 p_{Não})$$

$$Entropia(D) = -\left(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2}\right) = 1$$

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não

Nó Pai: Conjunto D

$$p_{Sim} = \frac{3}{6} = \frac{1}{2} \quad p_{Não} = \frac{3}{6} = \frac{1}{2}$$


$$Entropia(D) = -(p_{Sim} \log_2 p_{Sim} + p_{Não} \log_2 p_{Não})$$

$$Entropia(D) = -\left(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2}\right) = 1$$

Conjunto misturado


- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



Nó Filho: Salário Alto

$$\frac{|Salariao_{Alto}|}{|D|} = \frac{3}{6} = \frac{1}{2} \quad p_{Sim} = \frac{2}{3} \quad p_{Não} = \frac{1}{3}$$

$$Entropia(Salariao_{Alto}) = -\left(\frac{2}{3}\log_2\frac{2}{3} + \frac{1}{3}\log_2\frac{1}{3}\right) = 0,92$$


Nó Filho: Salário Baixo

$$\frac{|Salariao_{Baixo}|}{|D|} = \frac{3}{6} = \frac{1}{2} \quad p_{Sim} = \frac{1}{3} \quad p_{Não} = \frac{2}{3}$$

$$Entropia(Salariao_{Baixo}) = -\left(\frac{1}{3}\log_2\frac{1}{3} + \frac{2}{3}\log_2\frac{2}{3}\right) = 0,92$$

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não




Ganho de informação para o atributo salário

$$GI(D, Salário) = Entropia_{Pai} - \sum_{j=1}^m Peso_{Filho} Entropia_{Filho}$$

$$GI(D, Salário) = 1 - \left(\frac{1}{2} \times 0,92 + \frac{1}{2} \times 0,92 \right) = 0,08$$

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



Ganho de informação para o atributo salário


$$GI(D, Salário) = Entropia_{Pai} - \sum_{j=1}^m Peso_{Filho} Entropia_{Filho}$$

$$GI(D, Salário) = 1 - \left(\frac{1}{2} \times 0,92 + \frac{1}{2} \times 0,92 \right) = 0,08$$

Muito misturado, houve um baixo ganho de informação


- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



Nó Filho: Localização Longe

$$\frac{|Localização_{Longe}|}{|D|} = \frac{4}{6} \quad p_{Sim} = \frac{2}{4} = \frac{1}{2} \quad p_{Não} = \frac{2}{4} = \frac{1}{2}$$

$$Entropia(Localização_{Longe}) = -\left(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}\right) = 1$$

Nó Filho: Localização Perto

$$\frac{|Localização_{perto}|}{|D|} = \frac{2}{6} \quad p_{Sim} = \frac{1}{2} \quad p_{Não} = \frac{1}{2}$$

$$Entropia(Localização_{perto}) = -\left(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}\right) = 1$$


- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não

Ganho de informação para o atributo localização


$$GI(D, Localiza\c{c}o) = Entropia_{Pai} - \sum_{j=1}^m Peso_{Filho} Entropia_{Filho}$$

$$GI(D, Localia\c{c}ao) = 1 - \left(\frac{4}{6} \times 1 + \frac{2}{6} \times 1 \right) = 0$$



- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



Ganho de informação para o atributo localização

$$GI(D, Localiza\c{c}o) = Entropia_{Pai} - \sum_{j=1}^m Peso_{Filho} Entropia_{Filho}$$


Utilidade mínima

$$GI(D, Localia\c{c}ao) = 1 - \left(\frac{4}{6} \times 1 + \frac{2}{6} \times 1 \right) = 0$$

Muito misturado, não houve ganho de informação


- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



Nó Filho: Função Interessante

$$\frac{|Função_{Int}|}{|D|} = \frac{3}{6} \quad p_{Sim} = \frac{3}{3} = 1 \quad p_{Não} = \frac{0}{3} = 0$$

$$Entropia(Função_{Int.}) = -(1\log_2 1 + 0\log_2 0) = 0$$


Nó Filho: Função Desinteressante

$$\frac{|Função_{Des.}|}{|D|} = \frac{3}{6} \quad p_{Sim} = \frac{0}{3} = 0 \quad p_{Não} = \frac{3}{3} = 1$$

$$Entropia(Função_{Des.}) = -(0\log_2 0 + 1\log_2 1) = 0$$

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não




Ganho de informação para o atributo função

$$GI(D, Função) = Entropia_{Pai} - \sum_{j=1}^m Peso_{Filho} Entropia_{Filho}$$

$$GI(D, Função) = 1 - \left(\frac{3}{6} \times 0 + \frac{3}{6} \times 0 \right) = 1$$

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



Ganho de informação para o atributo função

$$GI(D, Função) = Entropia_{Pai} - \sum_{j=1}^m Peso_{Filho} Entropia_{Filho}$$

Utilidade máxima

$$GI(D, Função) = 1 - \left(\frac{3}{6} \times 0 + \frac{3}{6} \times 0 \right) = 1$$

Não houve mistura

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não

$$GI(D, Sal\acute{a}rio) = 1 - \left(\frac{1}{2} \times 0,92 + \frac{1}{2} \times 0,92 \right) = 0,08$$

$$GI(D, Localia\c{c}ao) = 1 - \left(\frac{4}{6} \times 1 + \frac{2}{6} \times 1 \right) = 0$$

$$GI(D, Fun\c{c}\tilde{a}o) = 1 - \left(\frac{3}{6} \times 0 + \frac{3}{6} \times 0 \right) = 1$$

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não


$$GI(D, Salário) = 1 - \left(\frac{1}{2} \times 0,92 + \frac{1}{2} \times 0,92 \right) = 0,08$$

$$GI(D, Localiação) = 1 - \left(\frac{4}{6} \times 1 + \frac{2}{6} \times 1 \right) = 0$$

$$GI(D, Função) = 1 - \left(\frac{3}{6} \times 0 + \frac{3}{6} \times 0 \right) = 1$$

- Aceitar ou recusar uma proposta de emprego.


ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não



- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não


E se não tivesse uma boa separação?



- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não

Continuo em cada ramo e reduzo o meu conjunto.




Continuo com o atributo localização, porém, removendo os exemplos que possuem o valor Desinteressante no atributo Função.

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
3	Baixo	Longe	Interessante	Sim
5	Alto	Perto	Interessante	Sim

O conjunto de dados é reduzido

Continuo em cada ramo e reduzo o meu conjunto.




Continuo com o atributo localização, porém, removendo os exemplos que possuem o valor Desinteressante no atributo Função.

- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não
7	Alto	Perto	Interessante	??


Nova instância



- Aceitar ou recusar uma proposta de emprego.

ID	Salário	Localização	Função	Decisão
1	Alto	Longe	Interessante	Sim
2	Baixo	Perto	Desinteressante	Não
3	Baixo	Longe	Interessante	Sim
4	Alto	Longe	Desinteressante	Não
5	Alto	Perto	Interessante	Sim
6	Baixo	Longe	Desinteressante	Não
7	Alto	Perto	Interessante	??

Nova instância



Vantagens e limitações

- Não-paramétrica.
- Seleciona os melhores atributos automaticamente.
- É interpretável.
- Eficiente e simples.



- Não-paramétrica.
- Seleciona os melhores atributos automaticamente.
- É interpretável.
- Eficiente e simples.



- Não-paramétrica.
- **Seleciona os melhores atributos automaticamente.**
- É interpretável.
- Eficiente e simples.



- Não-paramétrica.
- Seleciona os melhores atributos automaticamente.
- **É interpretável.**
- Eficiente e simples.



- Não-paramétrica.
- Seleciona os melhores atributos automaticamente.
- É interpretável.
- **Eficiente e simples.**



- Sensível a valores ausentes.
- Atributos contínuos = gargalo.
- Instabilidade:
 - Pequenas mudanças podem mudar completamente a árvore.

- **Sensível a valores ausentes.**
- Atributos contínuos = gargalo.
- Instabilidade:
 - Pequenas mudanças podem mudar completamente a árvore.

- Sensível a valores ausentes.
- Atributos contínuos = gargalo.
- Instabilidade:
 - Pequenas mudanças podem mudar completamente a árvore.

- Sensível a valores ausentes.
- Atributos contínuos = gargalo.
- **Instabilidade:**
 - Pequenas mudanças podem mudar completamente a árvore.

Próxima aula

- Outros algoritmo importantes

Obrigado



Dúvidas

Email: alanvalejo@ufscar.br

Acessar o fórum no Moodle

Comparecer ao plantão de dúvidas