

Universidade Federal de São Carlos - UFSCar
Departamento de Computação - DC
CEP 13565-905, Rod. Washington Luiz, s/n, São Carlos, SP

Avaliação de Algoritmos de Classificação


Prof. Dr. Alan Demétrius Baria Valejo

1001336 - Inteligência Artificial


- Introdução
- Treinamento
- Avaliação
- Questões importantes
- Próxima aula

Introdução

- Qual o cenário real?





- Qual o cenário real?



Introdução

Alguns conceitos básicos

- Qual o cenário real?




- Mas será que o algoritmo acertou esse resultado?

Introdução

Alguns conceitos básicos

- Importante:
 - Depois de pronto, em muitas aplicações, não temos mais como saber se o modelo acertou ou errou quando avaliado em dados futuros;
 - Apenas confiamos;
- Imaginem uma máquina que separa lixo reciclado e não reciclado:
 - Diariamente, toneladas de lixo são separadas por essa máquina;
 - Se precisássemos conferir se a máquina acertou ou não, não faria sentido a sua utilização;
 - Claro que eventualmente, um lixo não reciclado passa batido ou ao contrário;
 - Porém, isso é tolerável.
 - O importante é saber antes de sua aplicação se o algoritmo costuma errar pouco ou muito.



Introdução

Alguns conceitos básicos

- Importante:
 - Depois de pronto, em muitas aplicações, não temos mais como saber se o modelo acertou ou errou quando avaliado em dados futuros;
 - Apenas confiamos;
- Logicamente, existem cenários críticos, como o **diagnóstico médico**:
 - **Nesse caso, cada diagnóstico é verificado;**
 - Porém, se o diagnóstico estiver separado em positivo e negativo é mais fácil verificar ou encaminhar o paciente para outros exames.




Introdução

Alguns conceitos básicos

- Portanto:
 - Queremos saber, antes que o modelo seja implementado em produção, qual o grau de confiança em sua resposta ou o seu desempenho na aplicação;
- Antes do modelo ser aplicado em dados futuros, ele será avaliado.




- Essa avaliação é feita no conjunto de dados legados e não em produção ou nos dados futuros.



- Essa avaliação é feita no conjunto de dados legados e não em produção ou nos dados futuros.

- Porque?




Introdução

Alguns conceitos básicos

- Essa avaliação é feia no conjunto de dados legados e não em produção ou nos dados futuros.

- Porque?



- Simples, eu conheço os meus dados legados ou eu tenho um supervisor na empresa.


Introdução

Alguns conceitos básicos

- Essa avaliação é feita no conjunto de dados legados e não em produção ou nos dados futuros.

- E como fazemos isso?


- Porque?



- Simples, eu conheço os meus dados legados ou eu tenho um supervisor na empresa.

Introdução


Alguns conceitos básicos



Introdução

Alguns conceitos básicos


- O conjunto de treino é utilizado para treinar o modelo.



Introdução

Alguns conceitos básicos


- O conjunto de treino é utilizado para treinar o modelo.



Introdução

Alguns conceitos básicos


- O conjunto de treino é utilizado para treinar o modelo.



Introdução



Alguns conceitos básicos

- O conjunto de teste é utilizado para avaliar o modelo treinado.



- O conjunto de teste é utilizado para avaliar o modelo treinado.

Qual a grande sacada?





Introdução

Alguns conceitos básicos

- O conjunto de teste é utilizado para avaliar o modelo treinado.


Como o conjunto de teste é oriundo dos meus dados legados eu conheço a resposta.



Introdução

Alguns conceitos básicos


- O conjunto de teste é utilizado para avaliar o modelo treinado



Introdução

Alguns conceitos básicos

- Depois de avaliado e ajustado, o modelo pode ser colocado em produção.
- Ou seja, pode ser utilizado para classificar dados nunca antes vistos.




Introdução

Alguns conceitos básicos

- Depois de avaliado e ajustado, o modelo pode ser colocado em produção.
- Ou seja, pode ser utilizado para classificar dados nunca antes vistos.

Embora no conjunto de teste existiu 1 erro, em produção esse erro pode não ocorrer.





Treinamento

Conjunto de treino e teste

Como separar?

- O modelo não pode ver os dados de teste durante o treinamento.
- Caso isso ocorra, seria o equivalente a fazer uma prova sabendo de antemão quais são as questões e quais são as respostas.
- Ou seja, os testes devem ser feitos com dados que o modelo não viu anteriormente.





Algoritmo de aprendizado
 $\mathcal{A}$

Hipótese
 $g \approx f$

Conjunto de treino e teste

Como separar?

- O modelo não pode ver os dados de teste durante o treinamento.
- Caso isso ocorra, seria o equivalente a fazer uma prova sabendo de antemão quais são as questões e quais são as respostas.
- Ou seja, os testes devem ser feitos com dados que o modelo não viu anteriormente.





Algoritmo de aprendizado
 $\mathcal{A}$

Hipótese
 $g \approx f$

Conjunto de treino e teste

Como separar?

- O modelo não pode ver os dados de teste durante o treinamento.
- **Caso isso ocorra, seria o equivalente a fazer uma prova sabendo de antemão quais são as questões e quais são as respostas.**
- Ou seja, os testes devem ser feitos com dados que o modelo não viu anteriormente.





Algoritmo de aprendizado
 $\mathcal{A}$

Hipótese
 $g \approx f$

Conjunto de treino e teste

Como separar?

- O modelo não pode ver os dados de teste durante o treinamento.
- Caso isso ocorra, seria o equivalente a fazer uma prova sabendo de antemão quais são as questões e quais são as respostas.
- **Ou seja, os testes devem ser feitos com dados que o modelo não viu anteriormente.**




Algoritmo de aprendizado
 $\mathcal{A}$

Hipótese
 $g \approx f$

Conjunto de treino e teste

Hold-out


- O método mais simples de testar o modelo consiste em separar, de forma aleatória, uma parcela dos dados para testar o modelo, e utilizar o restante para treinamento.
- Isso é conhecido como *hold-out*.
- Geralmente, cerca de 30% dos dados são separados para teste.
- Essa técnica pode ser realizada várias vezes na mesma base de dados, para se obter a média do desempenho do classificador.
- Está sujeita à aleatoriedades do processo de treinamento e teste.
- Reduz a quantidade de amostras que podem ser usadas no treinamento.



Conjunto de treino e teste

Hold-out


- O **método mais simples** de testar o modelo consiste em separar, de forma **aleatória**, uma parcela dos dados para testar o modelo, e utilizar o restante para treinamento.
- Isso é conhecido como *hold-out*.
- Geralmente, cerca de 30% dos dados são separados para teste.
- Essa técnica pode ser realizada várias vezes na mesma base de dados, para se obter a média do desempenho do classificador.
- Está sujeita à aleatoriedades do processo de treinamento e teste.
- Reduz a quantidade de amostras que podem ser usadas no treinamento.



Conjunto de treino e teste

Hold-out


- O método mais simples de testar o modelo consiste em separar, de forma aleatória, uma parcela dos dados para testar o modelo, e utilizar o restante para treinamento.
- Isso é conhecido como *hold-out*.
- Geralmente, cerca de 30% dos dados são separados para teste.
- Essa técnica pode ser realizada várias vezes na mesma base de dados, para se obter a média do desempenho do classificador.
- Está sujeita à aleatoriedades do processo de treinamento e teste.
- Reduz a quantidade de amostras que podem ser usadas no treinamento.



Conjunto de treino e teste

Hold-out


- O método mais simples de testar o modelo consiste em separar, de forma aleatória, uma parcela dos dados para testar o modelo, e utilizar o restante para treinamento.
- Isso é conhecido como *hold-out*.
- **Geralmente, cerca de 30% dos dados são separados para teste.**
- Essa técnica pode ser realizada várias vezes na mesma base de dados, para se obter a média do desempenho do classificador.
- Está sujeita à aleatoriedades do processo de treinamento e teste.
- Reduz a quantidade de amostras que podem ser usadas no treinamento.



Conjunto de treino e teste

Hold-out


- O método mais simples de testar o modelo consiste em separar, de forma aleatória, uma parcela dos dados para testar o modelo, e utilizar o restante para treinamento.
- Isso é conhecido como *hold-out*.
- Geralmente, cerca de 30% dos dados são separados para teste.
- Essa técnica pode ser **realizada várias vezes** na mesma base de dados, para se obter a **média do desempenho do classificado**.
- Está sujeita à aleatoriedades do processo de treinamento e teste.
- Reduz a quantidade de amostras que podem ser usadas no treinamento.



Conjunto de treino e teste

Hold-out


- O método mais simples de testar o modelo consiste em separar, de forma aleatória, uma parcela dos dados para testar o modelo, e utilizar o restante para treinamento.
- Isso é conhecido como *hold-out*.
- Geralmente, cerca de 30% dos dados são separados para teste.
- Essa técnica pode ser realizada várias vezes na mesma base de dados, para se obter a média do desempenho do classificador.
- **Está sujeita à aleatoriedades do processo de treinamento e teste.**
- Reduz a quantidade de amostras que podem ser usadas no treinamento.




Conjunto de treino e teste

Hold-out

- O método mais simples de testar o modelo consiste em separar, de forma aleatória, uma parcela dos dados para testar o modelo, e utilizar o restante para treinamento.
- Isso é conhecido como *hold-out*.
- Geralmente, cerca de 30% dos dados são separados para teste.
- Essa técnica pode ser realizada várias vezes na mesma base de dados, para se obter a média do desempenho do classificador.
- Está sujeita à aleatoriedades do processo de treinamento e teste.
- **Reduz a quantidade de amostras que podem ser usadas no treinamento.**



- **Problema!**
 - Algumas classes podem ficar sem representantes ou com poucos representantes (insuficiente para treinamento).
 - A distribuição do número de elementos em cada classe no conjunto original pode não estar representada no conjunto de treino e teste.



- Na separação estratificada, primeiro, identificamos a proporção de exemplos em cada classe, por exemplo:
 - Suponha uma base de dados com 60% de dados positivos e 40% de dados negativos;
 - Na separação do conjunto de treino e teste, independente da técnica, **ambos terão a mesma proporção de dados de cada classe**;
 - O objetivo é que tanto o **conjunto de treino quanto o de teste** sejam **representativos** em termos de proporção de classes.
 - Entretanto, **nem sempre conseguimos** selecionar **exatamente** as **distribuições original** das classes, porém, o ideal é que a separação se aproxime da distribuição original de classes.

Conjunto de treino e teste

Separação estratificada

ID	Comprimento Sépala	Largura Sépala	Classe
1	5.1	3.5	Setosa
2	4.9	3.0	Setosa
3	4.7	3.2	Setosa
4	5.0	3.4	Setosa
5	5.4	3.9	Setosa
6	7.0	3.2	Versicolor
7	6.4	3.2	Versicolor
8	6.9	3.1	Versicolor
9	6.3	3.3	Versicolor
10	5.8	2.7	Setosa

- Total:
 - Setosa = 6 amostras (60%);
 - Versicolor = 4 amostras (40%).
- Separação *Holdout* Estratificada (70% treino, 30% teste):
 - Cálculo da divisão por classe:
 - Setosa: $6 \times 70\% = 4.2 \rightarrow 4$ no treino, 2 no teste;
 - Versicolor: $4 \times 70\% = 2.8 \rightarrow 3$ no treino, 1 no teste.

- Conjunto total (10 instâncias)
 - Setosa $\rightarrow [1, 2, 3, 4, 5, 10]$ (6 instâncias);
 - Versicolor $\rightarrow [6, 7, 8, 9]$ (4 instâncias).
- *Holdout* estratificado (70% / 30%):
 - Treino:
 - Setosa $\rightarrow [1, 2, 3, 4]$;
 - Versicolor $\rightarrow [6, 7, 8]$.
 - Teste:
 - Setosa $\rightarrow [5, 10]$;
 - Versicolor $\rightarrow [9]$.

- Porque 70%/30%?
 - No passado — anos noventa e início dos anos dois mil — **dados eram extremamente escassos.**
 - Os datasets clássicos (Iris, Wine, Sonar, Glass, Breast Cancer, etc.) tinham:
 - Dezenas;
 - Centenas;
 - ou, no máximo, poucos milhares de instâncias.
 - Naquela época, **cada amostra era valiosa.**
 - Se você separasse em cinquenta por cento e cinquenta por cento, perderia metade do dataset para treinar — e isso mataria a capacidade de modelos simples aprenderem.
 - Por isso surgiu a cultura de:
 - **treino grande;**
 - **teste pequeno;**
 - **maximizar o uso de cada instância de treino.**

- Porque 70%/30%?
 - **No passado — anos noventa e início dos anos dois mil — dados eram extremamente escassos.**
 - Os datasets clássicos (Iris, Wine, Sonar, Glass, Breast Cancer, etc.) tinham:
 - Dezenas;
 - Centenas;
 - ou, no máximo, poucos milhares de instâncias.
 - **Naquela época, cada amostra era valiosa.**
 - Se você separasse em cinquenta por cento e cinquenta por cento, perderia metade do dataset para treinar — e isso mataria a capacidade de modelos simples aprenderem.
 - **Por isso surgiu a cultura de:**
 - **treino grande;**
 - **teste pequeno;**
 - **maximizar o uso de cada instância de treino.**

- **A explicação matemática por trás do 70/30:**
 - A divisão entre treino e teste envolve um **trade-off entre viés e variância**:
 - **Treino maior → menor viés do modelo**:
 - Com mais dados, o modelo aprende melhor e o erro de treino fica mais próximo do erro real.
 - **Teste maior → menor variância da estimativa**:
 - Com mais amostras no teste, a avaliação final é mais estável e menos sensível à sorte.
 - Setenta por cento e trinta por cento e oitenta por cento e vinte por cento são divisões clássicas porque, nos conjuntos pequenos:
 - uma parte pequena (vinte ou trinta por cento) já oferece um teste **minimamente estável**;
 - a parte maior (setenta ou oitenta por cento) maximiza o treino, reduzindo o viés;
 - Esse equilíbrio é matematicamente razoável.
 - Mas **isso só importa quando o dataset é pequeno ou moderado**.

- **A explicação matemática por trás do 70/30:**
 - A divisão entre treino e teste envolve um **trade-off entre viés e variância**:
 - **Treino maior → menor viés do modelo:**
 - Com mais dados, o modelo aprende melhor e o erro de treino fica mais próximo do erro real.
 - **Teste maior → menor variância da estimativa:**
 - Com mais amostras no teste, a avaliação final é mais estável e menos sensível à sorte.
 - Setenta por cento e trinta por cento e oitenta por cento e vinte por cento são divisões clássicas porque, nos conjuntos pequenos:
 - uma parte pequena (vinte ou trinta por cento) já oferece um teste **minimamente estável**;
 - a parte maior (setenta ou oitenta por cento) maximiza o treino, reduzindo o viés;
 - Esse equilíbrio é matematicamente razoável.
 - **Mas isso só importa quando o dataset é pequeno ou moderado.**

- **Então o que vale em big data?**
 - Em big data, a pergunta muda:
 - **Quanto posso colocar no teste sem atrapalhar o custo computacional?**
 - Em muitos sistemas, armazenar milhões de instâncias para teste:
 - aumenta o custo;
 - aumenta o tempo de avaliação;
 - exige mais memória;
 - exige mais infraestrutura.
 - Por isso, você pode ver **testes pequenos**, como cinco por cento, e mesmo assim a avaliação é ótima.
- Exemplo:
 - Alguns trabalhos, por exemplo, usam **noventa e cinco por cento para treino e/ou cinco por cento para teste**, e o resultado é perfeitamente estável, como dito em:
 - “With tens of millions of training examples, we reserve only 1–5% for testing.” - *Large-Scale Machine Learning Systems*, ACM Computing Surveys, 2017.
 - “In large-scale settings with millions of samples, validation and test sets often comprise a small fraction of data, typically around 1–5%.” - *Industrial-Scale Machine Learning: Challenges and Applications*, ACM Computing Surveys, 2022.
 - “For very large datasets, allocating even 1% for evaluation can result in millions of samples, which is more than enough for stable statistics.” - Hapke & Nelson, *Deploying Machine Learning Models*, O’Reilly, 2020.

- **Então o que vale em big data?**
 - Em big data, a pergunta muda:
 - **Quanto posso colocar no teste sem atrapalhar o custo computacional?**
 - Em muitos sistemas, armazenar milhões de instâncias para teste:
 - aumenta o custo;
 - aumenta o tempo de avaliação;
 - exige mais memória;
 - exige mais infraestrutura.
 - **Por isso, você pode ver testes pequenos, como cinco por cento, e mesmo assim a avaliação é ótima.**
- Exemplo:
 - **Alguns trabalhos, por exemplo, usam noventa e cinco por cento para treino e/ou cinco por cento para teste**, e o resultado é perfeitamente estável, como dito em:
 - “With tens of millions of training examples, we reserve only 1–5% for testing.” - *Large-Scale Machine Learning Systems*, ACM Computing Surveys, 2017.
 - “In large-scale settings with millions of samples, validation and test sets often comprise a small fraction of data, typically around 1–5%.” - *Industrial-Scale Machine Learning: Challenges and Applications*, ACM Computing Surveys, 2022.
 - “For very large datasets, allocating even 1% for evaluation can result in millions of samples, which is more than enough for stable statistics.” - Hapke & Nelson, *Deploying Machine Learning Models*, O’Reilly, 2020.

- **Qual é o problema matemático do *hold-out*?**
 - O problema é: **a estimativa depende da sorte.**
 - Se a divisão 80/20 ou 70/30 pegou:
 - exemplos fáceis no teste → o modelo parece melhor do que é;
 - exemplos difíceis no teste → parece pior do que é.
 - Matematicamente, isso significa:
 - **Alta variância na estimativa do erro;**
 - **A avaliação muda quando você troca o *random seed*;**
 - **A divisão única não é representativa da distribuição real;**
 - **Você está usando poucos dados para avaliar** (especialmente em datasets pequenos).

- **Qual é o problema matemático do *hold-out*?**
 - O problema é: **a estimativa depende da sorte.**
 - Se a divisão 80/20 ou 70/30 pegou:
 - **exemplos fáceis no teste** → o modelo parece melhor do que é;
 - **exemplos difíceis no teste** → parece pior do que é.
 - Matematicamente, isso significa:
 - **Alta variância na estimativa do erro;**
 - **A avaliação muda quando você troca o *random seed*;**
 - **A divisão única não é representativa da distribuição real;**
 - **Você está usando poucos dados para avaliar** (especialmente em datasets pequenos).

- **Como isso aparece na prática?**
 - Se você repetir o *hold-out* com diferentes seeds:
 - O modelo pode ter 85%, 89%, 84%, 90% de desempenho.
 - Ou seja:
 - **O resultado não é confiável;**
 - **Não existe estabilidade estatística.**
 - E o mais grave:
 - Às vezes você acha que um modelo é melhor do que o outro só por sorte da divisão.

- **Como isso aparece na prática?**
 - Se você repetir o *hold-out* com diferentes seeds:
 - O modelo pode ter 85%, 89%, 84%, 90% de desempenho.
 - Ou seja:
 - **O resultado não é confiável;**
 - **Não existe estabilidade estatística.**
 - E o mais grave:
 - Às vezes você acha que um modelo é melhor do que o outro só por sorte da divisão.

- *Cross-validation* responde exatamente a esta pergunta:
 - “E se eu treinar e testar em **várias divisões diferentes** e depois combinar as avaliações utilizando média e desvio padrão?”.
- Matematicamente, isso reduz drasticamente:
 - **Variância** da estimativa;
 - **Dependência da sorte**;
 - **Tendência causada por uma única divisão ruim.**
- E aumenta:
 - **Representatividade da avaliação**;
 - **Utilização total do dataset**;
 - **Confiabilidade na comparação entre modelos.**

- *Cross-validation* responde exatamente a esta pergunta:
 - “E se eu treinar e testar em **várias divisões diferentes** e depois combinar as avaliações utilizando média e desvio padrão?”.
- Matematicamente, isso reduz drasticamente:
 - **Variância** da estimativa;
 - **Dependência da sorte**;
 - **Tendência causada por uma única divisão ruim.**
- E aumenta:
 - **Representatividade da avaliação**;
 - **Utilização total do dataset**;
 - **Confiabilidade na comparação entre modelos.**

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.
- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos *10-fold cross-validation*.
- Temos o seguinte processo:
 1. Dividimos o conjunto em k grupos:
 2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam um único grupo, utilizado para o treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste, salvamos o valor da métrica e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
 3. Analisamos as métricas em cada uma das iterações.

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.

- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos 10-fold cross-validation.

- Temos o seguinte processo:

1. Dividimos o conjunto em k grupos:
2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam o conjunto de treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
3. Analisamos as métricas em cada uma das iterações.

Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Fold 1	Fold 2	Fold 3	Fold 4	Fold 5

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.
- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos *10-fold cross-validation*.
- Temos o seguinte processo:
 1. Dividimos o conjunto em k grupos:
 2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam um único grupo, utilizado para o treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste, salvamos o valor da métrica e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
 3. Analisamos as métricas em cada uma das iterações.

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.
- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos *10-fold cross-validation*.
- Temos o seguinte processo:
 1. **Dividimos o conjunto em k grupos:**
 2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam um único grupo, utilizado para o treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste, salvamos o valor da métrica e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
 3. Analisamos as métricas em cada uma das iterações.

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.
- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos *10-fold cross-validation*.
- Temos o seguinte processo:
 1. Dividimos o conjunto em k grupos:
 2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam um único grupo, utilizado para o treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste, salvamos o valor da métrica e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
 3. Analisamos as métricas em cada uma das iterações.

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.
- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos *10-fold cross-validation*.
- Temos o seguinte processo:
 1. Dividimos o conjunto em k grupos:
 2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam um único grupo, utilizado para o treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste, salvamos o valor da métrica e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
 3. Analisamos as métricas em cada uma das iterações.

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.
- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos *10-fold cross-validation*.
- Temos o seguinte processo:
 1. Dividimos o conjunto em k grupos:
 2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam um único grupo, utilizado para o treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste, salvamos o valor da métrica e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
 3. Analisamos as métricas em cada uma das iterações.

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.
- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos *10-fold cross-validation*.
- Temos o seguinte processo:
 1. Dividimos o conjunto em k grupos:
 2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam um único grupo, utilizado para o treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste, salvamos o valor da métrica e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
 3. Analisamos as métricas em cada uma das iterações.


Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Na validação cruzada, o conjunto de dados é dividido aleatoriamente em “ k ” grupos.
- Usamos o número “ k ” para fazer referência ao teste
 - Por exemplo: $k=10$ temos *10-fold cross-validation*.
- Temos o seguinte processo:
 1. Dividimos o conjunto em k grupos:
 2. Fazemos uma iteração para cada grupo (k iterações):
 - A. O grupo selecionado é separado para teste, enquanto os demais se tornam um único grupo, utilizado para o treinamento;
 - B. Treinamos um modelo com os dados de treinamento, testamos com os dados de teste, salvamos o valor da métrica e descartamos o modelo;
 - C. O próximo grupo é selecionado e voltamos ao passo A;
 3. **Analizamos as métricas em cada uma das iterações.**

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)



<http://karlrosaen.com/ml/learning-log/2016-06-20/>

Conjunto de treino e teste

Validação cruzada (*k-fold cross-validation*)

- Instâncias = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10].
- A cada iteração, uma instância diferente será usada como teste e as outras 9 como treino.

<i>Fold</i>	Teste	Treino
1	[1]	[2, 3, 4, 5, 6, 7, 8, 9, 10]
2	[2]	[1, 3, 4, 5, 6, 7, 8, 9, 10]
3	[3]	[1, 2, 4, 5, 6, 7, 8, 9, 10]
4	[4]	[1, 2, 3, 5, 6, 7, 8, 9, 10]
5	[5]	[1, 2, 3, 4, 6, 7, 8, 9, 10]
6	[6]	[1, 2, 3, 4, 5, 7, 8, 9, 10]
7	[7]	[1, 2, 3, 4, 5, 6, 8, 9, 10]
8	[8]	[1, 2, 3, 4, 5, 6, 7, 9, 10]
9	[9]	[1, 2, 3, 4, 5, 6, 7, 8, 10]
10	[10]	[1, 2, 3, 4, 5, 6, 7, 8, 9]

- *K-Fold* com $k = 10$:
 - A cada iteração, uma instância diferente será usada como teste e as outras 9 como treino;
 - Cada instância será usada exatamente uma vez como teste, e nove vezes como treino.

Avaliação

- Representação do erro por classe.
- A matriz de confusão ajuda a avaliar o desempenho do modelo de classificação no aprendizado de máquina **comparando os valores previstos com os valores reais de um conjunto de dados.**

		Classe predita	
		Positivo	Negativo
Classe Verdadeira	Positivo	VP	FN
	Negativo	FP	VN

<https://www.ibm.com/br-pt/topics/confusion-matrix>

Avaliação

Matriz de confusão

- Representação do erro por classe.
- A matriz de confusão ajuda a avaliar o desempenho do modelo de classificação no aprendizado de máquina comparando os valores previstos com os valores reais de um conjunto de dados.

		Classe predita		
		1	2	3
Classe verdadeira	1	11	1	3
	2	1	4	0
	3	2	1	6

LORENA, Ana Carolina; GAMA, João; FACELI, Katti. Inteligência Artificial: Uma abordagem de aprendizado de máquina. Grupo Gen-LTC, 2011.

Avaliação

Matriz de confusão

- Dada uma amostra de 13 fotos, 8 de gatos e 5 de cachorros, onde os gatos pertencem à classe 1 e os cães pertencem à classe 0:
 - Dados reais = [1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0].
- Suponha que um classificador que distingue entre cachorros e gatos seja treinado. Das 13 fotos examinadas, o classificador faz 8 previsões precisas e erra 5, sendo que 3 gatos são erroneamente previstos como cachorros (primeiras 3 previsões) e 2 cachorros são erroneamente previstos como gatos (últimas 2 previstos):
 - Predição = [0, 0, 0, 1, 1, 1, 1, 1, 0, 0, 0, 1, 1].
- Com esses dois conjuntos rotulados (reais e previsões), podemos criar uma matriz de confusão que resumirá os resultados do teste do classificador:

														Classe predita				
														Gato	Cachorro			
Real		1	1	1	1	1	1	1	1	0	0	0	0	0	Classe Verdadeira	Gato	VP = 5	FN = 3
Predito		0	0	0	1	1	1	1	1	0	0	0	1	1		Cachorro	FP = 2	VN = 3

https://pt.wikipedia.org/wiki/Matriz_de_confus%C3%A3o

Avaliação

Matriz de confusão

- Dada uma amostra de 13 fotos, 8 de gatos e 5 de cachorros, onde os gatos pertencem à classe 1 e os cães pertencem à classe 0:
 - Dados reais = [1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0].
- Suponha que um classificador que distingue entre cachorros e gatos seja treinado. Ele faz 8 previsões precisas e erra 5, sendo que 3 gatos são erroneamente previstos como cachorros e 2 cachorros são erroneamente previstos como gatos (últimas 2 previstos):
 - Predição = [0, 0, 0, 1, 1, 1, 1, 1, 0, 0, 0, 1, 1].
- Com esses dois conjuntos rotulados (reais e previsões), podemos criar uma matriz de confusão que resumirá os resultados do teste do classificador:

É fácil inspecionar visualmente a tabela em busca de erros de previsão, pois eles serão representados por valores fora da diagonal.

														Classe predita			
														Gato	Cachorro		
Real	1	1	1	1	1	1	1	1	0	0	0	0	0	Classe Verdadeira	Gato	VP = 5	FN = 3
Predito	0	0	0	1	1	1	1	1	0	0	0	1	1		Cachorro	FP = 2	VN = 3

[https://pt.wikipedia.org/wiki/Matriz de confus%C3%A3o](https://pt.wikipedia.org/wiki/Matriz_de_confus%C3%A3o)

Avaliação


Matriz de confusão

- É claro que esse modelo é para um problema de classificação binária.
- A **matriz de confusão** também **pode visualizar resultados para problemas de classificação multiclass**.
- Por exemplo:
 - Imagine que estamos desenvolvendo um modelo de classificação de espécies como parte de um programa de conservação da vida marinha;
 - O modelo prevê as espécies de peixes. Uma matriz de confusão para um problema de classificação multiclass poderia ter a seguinte aparência:

Actual value	Walleye	TP			
	Largemouth Bass		TP		
	Bluegill			TP	
	Rainbow Trout				TP
		Walleye	Largemouth Bass	Bluegill	Rainbow Trout
		Predicted value			

<https://www.ibm.com/br-pt/topics/confusion-matrix>

- É claro que esse modelo é para um problema de classificação binária.
 - **Resultados para problemas de classificação multiclass.**
 - Todas as células da **diagonal** indicam:
 - **Verdadeiros positivos** previstos.
 - As **outras células** fornecem quantidades para:
 - **Falsos positivos;**
 - **Falsos negativos;** e
 - **Verdadeiros negativos.**
- Modelo de classificação de espécies como parte de um programa de conservação
- matriz de confusão para um problema de classificação multiclass poderia




	Walleye	Largemouth Bass	Bluegill	Rainbow Trout
Actual value	Walleye	Largemouth Bass	Bluegill	Rainbow Trout
	TP			
		TP		
			TP	
				TP
	Walleye	Largemouth Bass	Bluegill	Rainbow Trout
	Predicted value			

<https://www.ibm.com/br-pt/topics/confusion-matrix>

Avaliação

Matriz de confusão

- Representação do erro por classe considerando um problema multiclasse.



Mingwen Dong, Convolutional Neural Network Achieves Human-level Accuracy in Music Genre Classification, 2018


- Representação do erro por classe em problema de diagnóstico de risco a uma determinada doença:
 - Paciente com alto risco +;
 - Paciente com baixo risco -.

		Classe predita	
		+	-
Classe Verdadeira	+	VP	FN
	-	FP	VN

LORENA, Ana Carolina; GAMA, João; FACELI, Katti. Inteligência Artificial: Uma abordagem de aprendizado de máquina. Grupo Gen-LTC, 2011.

- **Acurácia:**
 - Taxa de acerto da classificação, ou seja, dos itens retornados, qual foi a porcentagem de acerto.
- **Erro:**
 - Taxa de erro da classificação, ou seja, dos itens retornados, qual foi a porcentagem de erro.

		Classe predita	
		+	-
Classe Verdadeira	+	VP	FN
	-	FP	VN



$$n = VP + FP + VN + FN$$

$$acc(f) = \frac{VP + VN}{n} = 1 - err(f)$$

$$err(f) = \frac{FP + FN}{n}$$

LORENA, Ana Carolina; GAMA, João; FACELI, Katti. Inteligência Artificial: Uma abordagem de aprendizado de máquina. Grupo Gen-LTC, 2011.

- Dada uma amostra de 20 fotos, 10 de macacos e 10 de sapos, onde os macacos pertencem à classe 0 e os sapos pertencem à classe 1:
 - Dados reais = [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1].
- Suponha que um classificador que distingue entre macacos e sapos e gatos seja treinado e obtenha o seguinte resultado:
 - Predição = [0, 1, 0, 1, 0, 0, 0, 0, 0, 0, 1, 1, 0, 1, 1, 0, 1, 0, 1, 1].
- Com esses dois conjuntos rotulados (reais e previsões), podemos criar uma matriz de confusão que resumirá os resultados do teste do classificador:

		Classe predita	
		Macaco	Sapo
Classe Verdadeira	Macaco	?	?
	Sapo	?	?

LORENA, Ana Carolina; GAMA, João; FACELI, Katti. Inteligência Artificial: Uma abordagem de aprendizado de máquina. Grupo Gen-LTC, 2011.

- Dada uma amostra de 20 fotos, 10 de macacos e 10 de sapos, onde os macacos pertencem à classe 0 e os sapos pertencem à classe 1:
 - Dados reais = [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1].
- Suponha que um classificador que distingue entre macacos e sapos e gatos seja treinado e obtenha o seguinte resultado:
 - Predição = [0, 1, 0, 1, 0, 0, 0, 0, 0, 0, 1, 1, 0, 1, 1, 0, 1, 0, 1, 1].
- Com esses dois conjuntos rotulados (reais e previsões), podemos criar uma matriz de confusão que resumirá os resultados do teste do classificador:

		Classe predita	
		Macaco	Sapo
Classe Verdadeira	Macaco	8	2
	Sapo	3	7

LORENA, Ana Carolina; GAMA, João; FACELI, Katti. Inteligência Artificial: Uma abordagem de aprendizado de máquina. Grupo Gen-LTC, 2011.

- Agora, podemos computar as medidas de qualidade.

$$acc(f) = \frac{VP + VN}{n} = ?$$

$$err(f) = \frac{FP + FN}{n} = ?$$

		Classe predita	
		Macaco	Sapo
Classe Verdadeira	Macaco	8	2
	Sapo	3	7

- Agora, podemos computar as medidas de qualidade.

$$acc(f) = \frac{VP + VN}{n} = \frac{8 + 7}{8 + 7 + 2 + 3} = 0,75$$

$$err(f) = \frac{FP + FN}{n} = \frac{2 + 3}{8 + 7 + 2 + 3} = 0,25$$

		Classe predita	
		Macaco	Sapo
Classe Verdadeira	Macaco	8	2
	Sapo	3	7

Avaliação

Métricas: Exemplo

- Vamos criar um exemplo ilustrativo para dois classificadores que avaliam pacientes com e sem Câncer.
- Teremos:
 - Classe Positiva (P): Pacientes com Câncer;
 - Classe Negativa (N): Pacientes sem Câncer.
- Vamos simular os dados para dois classificadores:

		<u>Classificador A</u>	
		Classe predita	
		+	-
Classe Verdadeira	+	20	30
	-	5	45

		<u>Classificador B</u>	
		Classe predita	
		+	-
Classe Verdadeira	+	45	5
	-	35	15

LORENA, Ana Carolina; GAMA, João; FACELI, Katti. Inteligência Artificial: Uma abordagem de aprendizado de máquina. Grupo Gen-LTC, 2011.

Classificador A

		Classe predita	
		+	-
Classe Verdadeira	+	20	30
	-	5	45

$$acc(f) = \frac{VP + VN}{n} = \frac{20 + 45}{20 + 30 + 5 + 45} = 0,65$$

$$err(f) = \frac{FP + FN}{n} = \frac{5 + 30}{20 + 30 + 5 + 45} = 0,35$$

Classificador B

		Classe predita	
		+	-
Classe Verdadeira	+	45	5
	-	35	15

$$acc(f) = \frac{VP + VN}{n} = \frac{15 + 45}{20 + 30 + 5 + 45} = 0,60$$

$$err(f) = \frac{FP + FN}{n} = \frac{5 + 35}{20 + 30 + 5 + 45} = 0,40$$

Classificador A

		Classe predita	
		+	-
Classe Verdadeira	+	20	30
	-	5	45

$$acc(f) = \frac{VP + VN}{n} = \frac{20 + 45}{20 + 30 + 5 + 45} = 0,65$$

$$err(f) = \frac{FP + FN}{n} = \frac{5 + 30}{20 + 30 + 5 + 45} = 0,35$$

Classificador B

		Classe predita	
		+	-
Classe Verdadeira	+	45	5
	-	35	15

$$acc(f) = \frac{VP + VN}{n} = \frac{15 + 45}{20 + 30 + 5 + 45} = 0,60$$

$$err(f) = \frac{FP + FN}{n} = \frac{5 + 35}{20 + 30 + 5 + 45} = 0,40$$

- Qual classificador é melhor?

Classificador A

		Classe predita	
		+	-
Classe Verdadeira	+	20	30
	-	5	45

$$acc(f) = \frac{VP + VN}{n} = \frac{20 + 45}{20 + 30 + 5 + 45} = 0,65$$

$$err(f) = \frac{FP + FN}{n} = \frac{5 + 30}{20 + 30 + 5 + 45} = 0,35$$

Classificador B

		Classe predita	
		+	-
Classe Verdadeira	+	45	5
	-	35	15

$$acc(f) = \frac{VP + VN}{n} = \frac{15 + 45}{20 + 30 + 5 + 45} = 0,60$$

$$err(f) = \frac{FP + FN}{n} = \frac{5 + 35}{20 + 30 + 5 + 45} = 0,40$$

- Qual classificador é melhor?
 - De acordo com a *acc* e *err*, o Classificador A é melhor.

Classificador A

Classe verdadeira

Classe predita

+

-

Classe Verdadeira

+

-

20

5

Classificador B

Classe predita

+

-

45

5

35

15



$$acc(f) = \frac{VP + VN}{n} = \frac{20 + 45}{20 + 30 + 5 + 45}$$

$$err(f) = \frac{FP + FN}{n} = \frac{5 + 30}{20 + 30 + 5 + 45}$$

$$acc(f) = \frac{15 + 45}{20 + 30 + 5 + 45} = 0,60$$

$$err(f) = \frac{5 + 35}{20 + 30 + 5 + 45} = 0,40$$


- Qual classificador é melhor?
 - De acordo com a *acc* e *err*, o Classificador A é melhor.

Classificador A

Class Verdadeira	Classe predita	
	0	1
0	10	10
1	10	10

$$acc(f) = \frac{VP + VN}{n}$$

$$err(f) = \frac{FP + FN}{n}$$



Classificador B

Class Verdadeira	Classe predita	
	0	1
0	20	5
1	30	45

$$acc(f) = \frac{VP + VN}{n}$$

$$err(f) = \frac{FP + FN}{n} = \frac{5 + 30}{20 + 30 + 5 + 45} = 0,40$$




- Qual classificador é melhor?
 - De acordo com a acc e err , o Classificador A é melhor.


Avaliação

Resumo das etapas


1. Divida o conjunto de dados em dois (de preferência 70–30%; no entanto, a porcentagem de divisão pode variar e deve ser aleatória).




2. Agora, treinamos o modelo no conjunto de dados de treinamento selecionando um conjunto fixo de hiperparâmetros durante o treinamento do modelo.



3. Use o conjunto de dados de teste para avaliar o modelo.



4. Use todo o conjunto de dados para treinar o modelo final para que ele possa ser melhor generalizado em conjuntos de dados futuros.



Próxima aula

- Aprendizado não supervisionado

Obrigado

Dúvidas

Email: alanvalejo@ufscar.br