

Algoritmos utilizados

- **K-Nearest Neighbors (KNN)**
- **Naive Bayes**
- **Árvore de Decisão**

Configuração experimental

- Holdout: 80% dos dados para treino e 20% para teste
- Divisão estratificada (stratify)
- random_state = 42 (para permitir que os testes sejam replicados)
- Standard scaler para KNN
- max_depth = 5 e class_weight='balanced' para árvore de decisão
- A avaliação foi feita analisando acurácia, recall e matriz de confusão dos modelos

KNN

- **Acurácia: ~78%**
- **Recall: apenas 20%**
- **Caiu na armadilha da acurácia**
- **Classificava quase todos como presentes**
- **Ruim para detectar faltas reais**

Naive Bayes

- **Recall: 42%**
- **Melhor que o KNN**
- **Desempenho intermediário**
- **Ainda perde muitos casos importantes**



Árvore de decisão

- Recall: 85% para pacientes ausentes
- Uso de `class_weight='balanced'`
- Penalização maior para erros da classe minoritária
- Melhor capacidade de prever faltas



Comparação dos modelos

Modelo	Acurácia global	Recall (Classe ausente)	Conclusão
K-NN	~78%	20%	Ruim para prever faltas (enviesado)
Naive Bayes	Médio	42%	Desempenho moderado
Árvore de decisão	Equilibrada	85%	Melhor desempenho prático

Discussão dos resultados

- Bases desbalanceadas dificultam a classificação
- Acurácia isolada pode gerar interpretações erradas
- O modelo deve priorizar identificação de faltas
- Aplicações Práticas:
 - Reagendamento inteligente
 - Confirmações extras
 - Redução de horários ociosos

Conclusão

- **Faltas não acontecem aleatoriamente**
- **Tempo de espera e bairro foram fatores decisivos**
- **A Árvore de Decisão apresentou melhor desempenho**
- **Benefícios Potenciais:**
 - Redução de custos**
 - Melhor aproveitamento de recursos públicos**
 - Diminuição da ociosidade hospitalar**



Limitações

- Ausência de histórico de faltas anteriores
- Não considera:
 - clima
 - transporte
 - feriados
- Possibilidade de alarmes falsos
- O modelo ainda necessita refinamento para uso real