

**Universidade Federal de São Carlos - UFSCar**  
Departamento de Computação - DC  
CEP 13565-905, Rod. Washington Luiz, s/n, São Carlos, SP


# Aula 04 – Aprendizado supervisionado: Classificação

**Prof. Dr. Alan Demétrius Baria Valejo**

1001524 - Aprendizado de Máquina 1

- Introdução
- Aprendizado supervisionado (definições, classificação *vs* regressão, especialista e classificação)
- Principais algoritmos de classificação
- Próxima aula

# Introdução





- Instância: Representação de um objeto do mundo real.
- Um atributo é uma **característica observável ou mensurável de uma instância**:
  - Em estatística: Variável.
- Cada amostra é descrita por um conjunto pré-definido de características, os seus “atributos”.

A curved grey arrow points from the gummy bear towards a data table. A light blue callout box labeled 'Dado ou valor' points to the cell containing the value '5' in the 'Altura/cm' column.

| Cor     | Peso/g | Sabor | Altura/cm | Largura/cm | Profundidade/cm |
|---------|--------|-------|-----------|------------|-----------------|
| Laranja | 10     | Menta | 5         | 2          | 1,5             |


- Considere um conjunto de dados  $X = \{x_1, x_2, x_3, \dots, x_n\}$ , onde  $n$  indica o número de exemplos (linhas da tabela).
- Cada objeto  $x_i$  possui  $m$  atributos, seja, o vetor de característica de tamanho  $m$ , tal que,  $x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{im})$ .

|       |           |                            |              |              |              |                                         |                           |               |
|-------|-----------|----------------------------|--------------|--------------|--------------|-----------------------------------------|---------------------------|---------------|
|       |           | Atributo $x_{i1}$ ou $A_1$ |              |              |              | Atributo $x_{im}$ ou $A_m$<br>ou classe |                           |               |
| $X =$ | <b>Id</b> | <b>Att 1</b>               | <b>Att 2</b> | <b>Att 3</b> | <b>Att 4</b> | <b>...</b>                              | <b>Att <math>m</math></b> |               |
|       | $x_1$     | $x_{11}$                   | $x_{12}$     | $x_{13}$     | $x_{14}$     | $\dots$                                 | $x_{1m}$                  | Exemplo $x_1$ |
|       | $x_2$     | $x_{21}$                   | $x_{22}$     | $x_{23}$     | $x_{24}$     | $\dots$                                 | $x_{1m}$                  |               |
|       | $\dots$   | $\dots$                    | $\dots$      | $\dots$      | $\dots$      | $\dots$                                 | $\dots$                   |               |
|       | $x_n$     | $x_{n1}$                   | $x_{n2}$     | $x_{n3}$     | $x_{n4}$     | $\dots$                                 | $x_{nm}$                  | Exemplo $x_n$ |

## Aprendizado supervisionado (definições, classificação vs regressão, especialista e classificação)

“A computer programming is said to **learn from experience E** with respect to some **task T** and some **performance measure P** if its performance on **T**, measured by **P**, improves with **E**”.

*Tom Mitchell, 1998*





- Aprovação de crédito/empréstimo.

| Idade | Sexo | Salário      | Anos na residência atual | Anos no emprego atual | Saldo na conta | Bom pagador |
|-------|------|--------------|--------------------------|-----------------------|----------------|-------------|
| 25    | M    | R\$ 2.200,00 | 2,5                      | 1                     | R\$ 2,53       | Sim         |

- Aprovação de crédito/empréstimo.

| Idade | Sexo | Salário      | Anos na residência atual | Anos no emprego atual | Saldo na conta | Bom pagador |
|-------|------|--------------|--------------------------|-----------------------|----------------|-------------|
| 25    | M    | R\$ 2.200,00 | 2,5                      | 1                     | R\$ 2,53       | Sim         |

T =

P =

E =

- Aprovação de crédito/empréstimo.

| Idade | Sexo | Salário      | Anos na residência atual | Anos no emprego atual | Saldo na conta | Bom pagador |
|-------|------|--------------|--------------------------|-----------------------|----------------|-------------|
| 25    | M    | R\$ 2.200,00 | 2,5                      | 1                     | R\$ 2,53       | Sim         |

T = Decidir entre o crédito ou não.

P =

E =

- Aprovação de crédito/empréstimo.

| Idade | Sexo | Salário      | Anos na residência atual | Anos no emprego atual | Saldo na conta | Bom pagador |
|-------|------|--------------|--------------------------|-----------------------|----------------|-------------|
| 25    | M    | R\$ 2.200,00 | 2,5                      | 1                     | R\$ 2,53       | Sim         |

T = Decidir entre o crédito ou não.

P = Quantos acertos, empréstimos que deram certo.

E =

- Aprovação de crédito/empréstimo.

| Idade | Sexo | Salário      | Anos na residência atual | Anos no emprego atual | Saldo na conta | Bom pagador |
|-------|------|--------------|--------------------------|-----------------------|----------------|-------------|
| 25    | M    | R\$ 2.200,00 | 2,5                      | 1                     | R\$ 2,53       | Sim         |

T = Decidir entre o crédito ou não.


P = Quantos acertos, empréstimos que deram certo.

E = Todos clientes rotulado como bom pagador ou não.

- Aprovação de crédito/empréstimo.

| Idade | Sexo | Salário      | Anos na residência atual | Anos no emprego atual | Saldo na conta | Bom pagador |
|-------|------|--------------|--------------------------|-----------------------|----------------|-------------|
| 25    | M    | R\$ 2.200,00 | 2,5                      | 1                     | R\$ 2,53       | Sim         |
| ...   | ...  | ...          | ...                      | ...                   | ...            | ...         |
| 28    | F    | R\$ 4.000,00 | 0,3                      | 4                     | R\$ -300,00    | ?           |

- Pergunta a ser respondida no Aprendizado Supervisionado:
  - Dado a minha experiência E, qual a classe (Sim, Não) do novo cliente?
- No aprendizado supervisionado queremos **prever ou prever a qual categoria (ou classe) um dado pertence.**



- **Aprendizado supervisionado é o paradigma de aprendizado de máquina voltado para tarefas preditivas.**
- Tarefas preditivas são aquelas cujo objetivo é prever um valor de saída  $y$  a partir de uma entrada  $x$ , com base em exemplos anteriores.
- **Predição aqui não significa prever o futuro, mas sim inferir uma saída desconhecida** a partir de um padrão aprendido.
- **Predição** significa inferir um valor desconhecido — não necessariamente futuro.
  - **Predição = inferir algo desconhecido.**
  - Classificar um e-mail como spam;
  - Identificar se uma imagem é gato ou cachorro.
- Mas quando estamos falando de análise temporal, aí sim temos:
  - **Predição = inferir o futuro;**
  - Prever preço amanhã;
  - Prever clima amanhã.
- Dado:
  - $(x, y)$ .
- Queremos aprender:
  - $f(x) \approx y$ .
- Ou seja:
  - Prever  $y$  para novos  $x$ .




- **Aprendizado supervisionado é o paradigma de aprendizado de máquina voltado para tarefas preditivas.**
- Tarefas preditivas são aquelas cujo **objetivo é prever um valor de saída  $y$  a partir de uma entrada  $x$** , com base em exemplos anteriores.
- **Predição aqui não significa prever o futuro, mas sim inferir uma saída desconhecida** a partir de um padrão aprendido.
- **Predição** significa inferir um valor desconhecido — não necessariamente futuro.
  - **Predição = inferir algo desconhecido.**
  - Classificar um e-mail como spam;
  - Identificar se uma imagem é gato ou cachorro.
- Mas quando estamos falando de análise temporal, aí sim temos:
  - **Predição = inferir o futuro;**
  - Prever preço amanhã;
  - Prever clima amanhã.
- Dado:
  - $(x, y)$ .
- Queremos aprender:
  - $f(x) \approx y$ .
- Ou seja:
  - Prever  $y$  para novos  $x$ .

- **Aprendizado supervisionado é o paradigma de aprendizado de máquina voltado para tarefas preditivas.**
- Tarefas preditivas são aquelas cujo objetivo é prever um valor de saída  $y$  a partir de uma entrada  $x$ , com base em exemplos anteriores.
- **Predição aqui não significa prever o futuro, mas sim inferir uma saída desconhecida** a partir de um padrão aprendido.
- **Predição** significa inferir um valor desconhecido — não necessariamente futuro.
  - **Predição = inferir algo desconhecido.**
    - Classificar um e-mail como spam;
    - Identificar se uma imagem é gato ou cachorro.
- Mas quando estamos falando de análise temporal, aí sim temos:
  - **Predição = inferir o futuro;**
  - Prever preço amanhã;
  - Prever clima amanhã.
- Dado:
  - $(x, y)$ .
- Queremos aprender:
  - $f(x) \approx y$ .
- Ou seja:
  - Prever  $y$  para novos  $x$ .

- **Aprendizado supervisionado é o paradigma de aprendizado de máquina voltado para tarefas preditivas.**
- Tarefas preditivas são aquelas cujo objetivo é prever um valor de saída  $y$  a partir de uma entrada  $x$ , com base em exemplos anteriores.
- **Predição aqui não significa prever o futuro, mas sim inferir uma saída desconhecida** a partir de um padrão aprendido.
- **Predição** significa inferir um valor desconhecido — não necessariamente futuro.
  - **Predição = inferir algo desconhecido.**
  - Classificar um e-mail como spam;
  - Identificar se uma imagem é gato ou cachorro.
- Mas quando estamos falando de análise temporal, aí sim temos:
  - **Predição = inferir o futuro;**
  - Prever preço amanhã;
  - Prever clima amanhã.
- Dado:
  - $(x, y)$ .
- Queremos aprender:
  - $f(x) \approx y$ .
- Ou seja:
  - Prever  $y$  para novos  $x$ .


### Classificação vs Regressão

- A diferença é simples, mas conceitualmente muito importante:
  - **Classificação:**
    - **Predizer uma classe (valor discreto);**
    - **Exemplos:**
      - Spam / Não spam;
      - Bom pagador / Mau pagador;
      - Gato / Cachorro.
    - **Forma:**  $y \in \{1,2,3,4, \dots, k\}$ , portanto,  $f: \mathbb{R}^m \rightarrow \{1,2,3,4, \dots, k\}$
  - **Regressão:**
    - **Predizer um valor numérico contínuo;**
    - **Exemplos:**
      - Preço de uma casa;
      - Temperatura;
      - Salário.
    - **Forma:**  $y \in \mathbb{R}$ , portanto,  $f: \mathbb{R}^m \rightarrow \mathbb{R}$




### Classificação vs Regressão

- A diferença é simples, mas conceitualmente muito importante:
  - **Classificação:**
    - **Predizer uma classe (valor discreto);**
    - **Exemplos:**
      - Spam / Não spam;
      - Bom pagador / Mau pagador;
      - Gato / Cachorro.
    - **Forma:**  $y \in \{1, 2, 3, 4, \dots, k\}$ , portanto,  $f: \mathbb{R}^m \rightarrow \{1, 2, 3, 4, \dots, k\}$
  - **Regressão:**
    - **Predizer um valor numérico contínuo;**
    - **Exemplos:**
      - Preço de uma casa;
      - Temperatura;
      - Salário.
    - **Forma:**  $y \in \mathbb{R}$ , portanto,  $f: \mathbb{R}^m \rightarrow \mathbb{R}$




## Classificação vs Regressão

- A diferença é simples, mas conceitualmente muito importante:
  - **Classificação:**
    - **Predizer uma classe (valor discreto);**
    - **Exemplos:**
      - Spam / Não spam;
      - Bom pagador / Mau pagador;
      - Gato / Cachorro.
    - **Forma:**  $y \in \{1,2,3,4, \dots, k\}$ , portanto,  $f: \mathbb{R}^m \rightarrow \{1,2,3,4, \dots, k\}$
  - **Regressão:**
    - **Predizer um valor numérico contínuo;**
    - **Exemplos:**
      - Preço de uma casa;
      - Temperatura;
      - Salário.
    - **Forma:**  $y \in \mathbb{R}$ , portanto,  $f: \mathbb{R}^m \rightarrow \mathbb{R}$




### Forma mais completa

- **Classificação**
  - $X = \{(x_i, y_i)\}_{i=1}^n \mid x_i \in \mathbb{R}^m, y_i \in \{1, 2, 3, 4, \dots, k\}$
- **Regressão**
  - $X = \{(x_i, y_i)\}_{i=1}^n \mid x_i \in \mathbb{R}^m, y_i \in \mathbb{R}$
- Assim:
  - Temos  $n$  exemplos;
  - Cada entrada tem  $m$  atributos;
  - Na classificação, a saída é discreta;
  - Na regressão, a saída é contínua.



- No aprendizado supervisionado, temos alguém (ou algum processo) rotulando cada exemplo da base de experiência:
  - “Professor” ou “Supervisor” ou “Especialista”;
  - Processo de coleta de coleta dos dados.









Cachorro



Gato




Gato



Cachorro



Gato



- Na tarefa de classificação, os rótulos são discretos.
- Objetivo é, para um dado não previamente rotulado, descobrir a qual classe ele pertence:
  - Lembrem-se do exemplo do empréstimo bancário.



Perfil A



Perfil A



Perfil A



Perfil B



Perfil B



Perfil C

- Na tarefa de classificação, os rótulos são discretos.
- **Objetivo é, para um dado não previamente rotulado, descobrir a qual classe ele pertence:**
  - Lembrem-se do exemplo do empréstimo bancário.



Perfil A



Perfil A



Perfil A



Perfil B



Perfil B



Perfil C



Perfil ???





Perfil A



Perfil A



Perfil A



Perfil B



Perfil B



Perfil C

Algoritmo de aprendizado  
 *$\mathcal{A}$*





Perfil A



Perfil A



Perfil A



Perfil B



Perfil B



Perfil C

Algoritmo de aprendizado  
 $\mathcal{A}$

Hipótese  
 $g \approx f$



Perfil A



Perfil A



Perfil A



Perfil B



Perfil B



Perfil C


Algoritmo de aprendizado  
 $\mathcal{A}$


Hipótese  
 $g \approx f$




Perfil ???











Conjunto de  
treinamento, dados  
históricos ou  
experiência


























Dado rotulado pelo  
modelo ou função  $g$


Posso jogar os dados de  
treinamento fora?











Algoritmo de aprendizado  
 $\mathcal{A}$

Hipótese  
 $g \approx f$

```
import numpy as np
import pandas as pd


train = pd.read_csv('HW6Train.csv')
test = pd.read_csv('HW6Test.csv')

def euclidean_distance(row1, row2):
    return np.sqrt(np.sum((row1[:-1] - row2[:-1])**2))

def get_neighbors(train, test_instance, num_neighbors):
    distances = []
    train_copy=train.copy()
    for j in range(len(train)):
        dist = euclidean_distance(test_instance, train.iloc[j,:])
        distances.append(dist)
    train_copy['distance']=distances
    return train_copy.nsmallest(num_neighbors, ['distance'])

def predict_classes(train, test, num_neighbors):
    prediction=[]
    for j in range(len(test)):
        neighbors = get_neighbors(train, test.iloc[j,:], num_neighbors)
        predicted_class = neighbors.variety.value_counts().index[0]
        prediction.append(predicted_class)
    return prediction

def compute_accuracy(prediction, test_y):
    return np.mean(prediction==test_y)
```



O modelo não é  
explicitamente  
programado






| <b>Id</b> | <b>Attr 1</b> | <b>Attr 2</b> | <b>Classe</b> |
|-----------|---------------|---------------|---------------|
| 1         | 0.5           | 1             | 1             |
| 2         | 2.9           | 1.9           | 1             |
| 3         | 1.2           | 3.1           | 1             |
| 4         | 0.8           | 4.7           | 1             |
| 5         | 2.7           | 5.4           | 1             |
| 6         | 8.1           | 4.7           | 2             |
| 7         | 8.3           | 6.6           | 2             |
| 8         | 6.3           | 6.7           | 2             |
| 9         | 8.0           | 9.1           | 2             |
| 10        | 5.4           | 8.4           | 2             |

Conjunto de  
treinamento


| Id | Attr 1 | Attr 2 | Classe |
|----|--------|--------|--------|
| 1  | 0.5    | 1      | 1      |
| 2  | 2.9    | 1.9    | 1      |
| 3  | 1.2    | 3.1    | 1      |
| 4  | 0.8    | 4.7    | 1      |
| 5  | 2.7    | 5.4    | 1      |
| 6  | 8.1    | 4.7    | 2      |
| 7  | 8.3    | 6.6    | 2      |
| 8  | 6.3    | 6.7    | 2      |
| 9  | 8.0    | 9.1    | 2      |
| 10 | 5.4    | 8.4    | 2      |





| Id | Attr 1 | Attr 2 | Classe |
|----|--------|--------|--------|
| 1  | 0.5    | 1      | 1      |
| 2  | 2.9    | 1.9    | 1      |
| 3  | 1.2    | 3.1    | 1      |
| 4  | 0.8    | 4.7    | 1      |
| 5  | 2.7    | 5.4    | 1      |
| 6  | 8.1    | 4.7    | 2      |
| 7  | 8.3    | 6.6    | 2      |
| 8  | 6.3    | 6.7    | 2      |
| 9  | 8.0    | 9.1    | 2      |
| 10 | 5.4    | 8.4    | 2      |
| 11 | 5.0    | 7.0    | ?      |




| Id | Attr 1 | Attr 2 | Classe |
|----|--------|--------|--------|
| 1  | 0.5    | 1      | 1      |
| 2  | 2.9    | 1.9    | 1      |
| 3  | 1.2    | 3.1    | 1      |
| 4  | 0.8    | 4.7    | 1      |
| 5  | 2.7    | 5.4    | 1      |
| 6  | 8.1    | 4.7    | 2      |
| 7  | 8.3    | 6.6    | 2      |
| 8  | 6.3    | 6.7    | 2      |
| 9  | 8.0    | 9.1    | 2      |
| 10 | 5.4    | 8.4    | 2      |
| 11 | 5.0    | 7.0    | 2      |
























## Principais algoritmos de classificação


- $K$ -NN.
- SVM.
- *Naïve Bayes*.
- Redes Neurais.
- Árvores de Decisão.



- Simplificação do Teorema de *Bayes*.






- Eu quero uma divisão do meu espaço que não esteja nem tão perto da classe 1 nem tão perto da classe 0.





- São sistemas inspirados nos neurônios biológicos e na estrutura maciçamente paralela do cérebro, com capacidade de adquirir, armazenar e utilizar conhecimento experimental.





Próxima aula

- $k$ -NN

Obrigado



**Dúvidas**

Email: [alanvalejo@ufscar.br](mailto:alanvalejo@ufscar.br)