

Universidade Federal de São Carlos - UFSCar
Departamento de Computação - DC
CEP 13565-905, Rod. Washington Luiz, s/n, São Carlos, SP

Aula 03 – Pré-processamento

Prof. Dr. Alan Demétrius Baria Valejo



1001524 - Aprendizado de Máquina 1

- Dados e conjuntos de dados
- Tipos de atributos
- Como modelar minhas observações ou medidas?
- Porque que pré-processar?
- Principais tarefas de pré-processamento
- Integração
- Limpeza
- Transformação
 - Normalização
 - Discretização
 - Codificação
- Redução
 - Atributo
 - Instância
- Conclusão
- Próxima aula

- Na **prova** irei cobrir questões mínimas, uma normalização ou discretização, **algo bem simples**, nada complexo.
- No **trabalho** essa parte **tem peso maior**, pois, provavelmente, vocês não irão encontrar conjuntos de dados na forma ideal para utilização.

Dados e conjuntos de dados

- Fatos, observações ou resultados de medição.
- Dados são valores atribuídos a algo.
- Descrição básica das coisas.
- Características de objetos ou entidades como pessoas.
- Estes valores não precisam ser necessariamente números.



- Instância: Representação de um objeto do mundo real.





- Instância: Representação de um objeto do mundo real.
- Um atributo é uma **característica observável ou mensurável de uma instância**:
 - Em estatística: Variável.
- Cada amostra é descrita por um conjunto pré-definido de características, os seus “atributos”.



- Instância: Representação de um objeto do mundo real.
- Um atributo é uma **característica observável ou mensurável de uma instância**:
 - Em estatística: Variável.
- Cada amostra é descrita por um conjunto pré-definido de características, os seus “atributos”.

Cor	Peso/g	Sabor	Altura/cm	Largura/cm	Profundidade/cm
Laranja	10	Menta	5	2	1,5



- Instância: Representação de um objeto do mundo real.
- Um atributo é uma **característica observável ou mensurável de uma instância**:
 - Em estatística: Variável.
- Cada amostra é descrita por um conjunto pré-definido de características, os seus “atributos”.

Atributo

Cor	Peso/g	Sabor	Altura/cm	Largura/cm	Profundidade/cm
Laranja	10	Menta	5	2	1,5



- Instância: Representação de um objeto do mundo real.
- Um atributo é uma **característica observável ou mensurável de uma instância**:
 - Em estatística: Variável.
- Cada amostra é descrita por um conjunto pré-definido de características, os seus “atributos”.

Cor	Peso/g	Sabor	Altura/cm	Largura/cm	Profundidade/cm
Laranja	10	Menta	5	2	1,5



- Os algoritmos de mineração de dados usam uma entrada estruturada no formato de tabela atributo-valor.

ID	Att 1	Att 2	Att 3	Att 4	...	Classe
1	0,1	Sim	548	Bom		A
2	0,5	Não	321	Médio		B
3	0,3	Sim	223	Ruim		A
...	...	...	...	...	...	...
n	0,2	Sim	7	Bom		B

- Os algoritmos de mineração de dados usam uma entrada estruturada no formato de tabela atributo-valor.

ID	Att 1	Att 2	Att 3	Att 4	...	Classe
1	0,1	Sim	548	Bom		A
2	0,5	Não	321	Médio		B
3	0,3	Sim	223	Ruim		A
...	...	...	...	...	...	...
n	0,2	Sim	7	Bom		B

Identificação das
instâncias

- Os algoritmos de mineração de dados usam uma entrada estruturada no formato de tabela atributo-valor.

Dado ou valor

ID	Att 1	Att 2	Att 3	Att 4	...	Classe
1	0,1	Sim	548	Bom		A
2	0,5	Não	321	Médio		B
3	0,3	Sim	223	Ruim		A
...	...	...	...	...	...	...
n	0,2	Sim	7	Bom		B

- Os algoritmos de mineração de dados usam uma entrada estruturada no formato de tabela atributo-valor.

Instância Exemplo

Registro
Tupla
Linha
Objeto

ID	Att 1	Att 2	Att 3	Att 4	...	Classe
1	0,1	Sim	548	Bom		A
2	0,5	Não	321	Médio		B
3	0,3	Sim	223	Ruim		A
...	...	...	...	...	...	...
n	0,2	Sim	7	Bom		B

Atributo
Variável
Coluna

- Os algoritmos de mineração de dados usam uma entrada estruturada de tabela atributo-valor.

ID	Att 1	Att 2	Att 3	Att 4	...	Classe
1	0,1	Sim	548	Bom		A
2	0,5	Não	321	Médio		B
3	0,3	Sim	223	Ruim		A
...	...	...	...	...	...	...
n	0,2	Sim	7	Bom		B

- Os algoritmos de mineração de dados usam uma entrada estruturada no formato de tabela atributo-valor.

Atributos previsores.

ID	Att 1	Att 2	Att 3	Att 4	...	Classe
1	0,1	Sim	548	Bom		A
2	0,5	Não	321	Médio		B
3	0,3	Sim	223	Ruim		A
...	...	...	...	...	...	...
n	0,2	Sim	7	Bom		B

- Atributo **Classe**, Preditivo, Alvo ou Rótulo (discreto ou não), quando for o caso.
- Atributo especial que descreve o fenômeno de interesse.
- Em geral, utilizado no Aprendizado Supervisionado.

ID	Att 1	Att 2	Att 3	Att 4	...	Classe
1	0,1	Sim	548	Bom		A
2	0,5	Não	321	Médio		B
3	0,3	Sim	223	Ruim		A
...	...	...	...	...	...	...
n	0,2	Sim	7	Bom		B

- Exemplos possíveis para o problema do tempo.

ID	Tempo	Temperatura	Umidade	Ventoso	Classe=Joga
1	Ensolarado	Quente	Normal	Verdadeiro	Não
2	Ensolarado	Quente	Normal	Falso	Sim
3	Nublado	Quente	Normal	Verdadeiro	Não
4	Nublado	Quente	Normal	Falso	Sim
5	Nublado	Fria	Normal	Verdadeiro	Sim
6	Chuvoso	Fria	Alta	Verdadeiro	Sim
7	Chuvoso	Fria	Normal	Falso	Não
8	Chuvoso	Amena	Alta	Verdadeiro	Não
9	Chuvoso	Fria	Alta	Verdadeiro	Não
10	Chuvoso	Amena	Alta	Falso	Sim
...	...	...	...	...	...

Tipos de atributos

- Qualitativo (ou categórico):
 - Nominal;
 - Ordinal.
- Quantitativo (ou numérico):
 - Discreto;
 - Contínuo.

- Nominal:
 - Não existe relação implícita entre valores nominais;
 - Não existe relação de ordem;
 - Tempo: “Ensolarado”, “Nublado”, “Chuvoso”;
 - Gênero: “Feminino”, “Masculino”;
 - Categoria de música: “Pop”, “Samba”, ..., “Rock”.
- Ordinal:
 - Existe uma ordem;
 - Alfabeto: “a”, “b”, “c”, ..., “z”;
 - Escolaridade: 1º, 2º, 3º graus;
 - Estágio da doença: “Inicial”, “Intermediário”, “Terminal”;
 - Mês: “janeiro”, “fevereiro”, ..., “dezembro”.

- Ordinais por natureza.
- Discreto:
 - Geralmente são o resultado de contagens;
 - Assumir apenas um número finito ou infinito contável.
- Contínuo:
 - Valores em uma escala contínua;
 - Usualmente devem ser medidas através de algum instrumento;
 - Peso (balança), altura (régua), tempo (relógio).

Nome	Idade $\in \mathbb{Z}$	Peso $\in \mathbb{R}$
Maria	23	69,2
João	25	70,1
Marcos	19	65,3
Cristina	32	65,6
Núbia	57	72,7
Antônio	45	80,5
...	...	...

Como modelar minhas observações ou medidas?

- Importante.
- **Nem sempre uma variável representada por números é quantitativa.**
- O número do telefone de uma pessoa, o número da casa, o número de sua identidade.
- Às vezes o sexo do animal é registrado na planilha de dados como 1 se “macho” e 2 se “fêmea”.
- Isto não significa que a variável sexo passou a ser quantitativa.

- Identificação numérica para cores
 - 1 = “amarelo”
 - 2 = “azul”
 - 3 = “verde”
 - 4 = “cinza”
 - ...

- Como modelar minhas observações ou medidas?
- Que tipo de dados eu obtenho com a seguinte pergunta:
 - Quantos livros possuí em casa?

- Como modelar minhas observações ou medidas?
- Que tipo de dados eu obtenho com a seguinte pergunta:
 - Quantos livros possui em casa?

- Numérico discreto $\in \mathbb{Z}$?
- 1
- 2
- 3
- 4
- 5
- ...

- Como modelar minhas observações ou medidas?
- Que tipo de dados eu obtenho com a seguinte pergunta:
 - Quantos livros possui em casa?

- Numérico discreto $\in \mathbb{Z}$?


- 1
- 2
- 3
- 4
- 5
- ...

- Nominal Ordinal

1. 0-10
2. 11-25
3. 26-100
4. 101-200
5. 201-500
6. 500+

- Como modelar minhas observações ou medidas?
- Que tipo de dados eu obtenho com a seguinte pergunta:
 - Quantos livros possui em casa?

- Numérico discreto $\in \mathbb{Z}$?
- 1
- 2
- 3
- 4
- 5
- ...



- Nominal Ordinal
 1. 0-10
 2. 11-25
 3. 26-100
 4. 101-200
 5. 201-500
 6. 500+

- Porque o tipo de dado importa?
 - Diferentes algoritmos podem ser capazes de lidar com apenas um tipo de dados;
 - Quando um algoritmo suporta vários tipos, defini-los inadequadamente pode causar danos ao aprendizado;
 - Pré-processamento “pode” ser relevante.

kNN

SVM

...

Árvores de Decisão

KMeans

DBScan

Naïve Bayes

...


- **Nem sempre** os dados possuem as **características explícitas**:
 - Chamamos esses dados de não-estruturados;
 - Uma opção é a extração ou aprendizado de atributos.



- **Nem sempre** os dados possuem as **características explícitas**:
 - Chamamos esses dados de não-estruturados;
 - Uma opção é a extração ou aprendizado de atributos.




- **Nem sempre** os dados possuem as **características explícitas**:
 - Chamamos esses dados de não-estruturados;
 - Uma opção é a extração ou aprendizado de atributos.



ID	Attr 1	Attr 2	Attr 3	Attr 4	Attr 5	...
1	1,3	1,5	2,4	3,8	8,7	...
2	4,5	6,8	9,5	1,2	0,8	...
3	3,2	3,5	4,0	1,5	5,1	...
4	...	...	...	...	...	...

Como modelar minhas observações ou medidas?

- **Nem sempre** os dados possuem as **características explícitas**:
 - Chamamos esses dados de não-estruturados;
 - Uma opção é a extração ou aprendizado de atributos.



Ginsparg, Paul & Houle, Paul & Joachims, Thorsten & Sul, Jae Hoon. (2004). Mapping Subsets of Scholarly Information. Proceedings of the National Academy of Sciences of the United States of America. 101 Suppl 1. 5236-40. 10.1073/pnas.0308253100.

Imagem

Texto

Sensores

ID	Att 1	Att 2	...	Classe
1	0,1	Sim		A
2	0,5	Não		B
3	0,3	Sim		A
...	...	...	...	...
n	0,2	Sim		B

Aprendizado de máquina

Porque que pré-processar?





- Os dados do mundo real estão sujeitos:
 - Incompletos: faltando valores;
 - Ruído: contendo erros ou *outliers*;
 - Inconsistente: Contém discrepâncias;
 - Duplicados: Várias instâncias representando o mesmo objeto.

Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos		23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983		R\$ 7,000
Núbia	57		72,7	R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...

Pré-processamento

Por que pré-processar é importante?



- Os dados do mundo real estão sujeitos:
 - Incompletos: faltando valores;
 - Ruído: contendo erros ou *outliers*;
 - Inconsistente: Contém discrepâncias;
 - Duplicados: Várias instâncias representando o mesmo objeto.

Nome	Idade	Nascimento	Peso	Salário
João	35	01/01/1987	69,2	R\$ 4,000
	47	08/04/1975	70,1	R\$ 3,500
Marcos		23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983		R\$ 7,000
Núbia	57		72,7	R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...

Incompleto

Pré-processamento

Por que pré-processar é importante?



- Os dados do mundo real estão sujeitos:
 - Incompletos: faltando valores;
 - Ruído: contendo erros ou *outliers*;
 - Inconsistente: Contém discrepâncias;
 - Duplicados: Várias instâncias representando o mesmo objeto.

Nome	Idade	Nascimento	Peso	Salário	
Incompleto	35	01/01/1987	69,2	R\$ 4,000	
	João	47	08/04/1975	70,1	R\$ 3,500
	Marcos		23/09/1979	65,3	R\$ 2,500
	Cristina	38	15/09/1983		R\$ 7,000
	Núbia	57		72,7	R\$ 9,500
	Antônio	49	10/03/2010	80,5	R\$ 0,001
	Antônio	49	10/03/2010	80,5	R\$ 0,001
	...	...	...	...	...

Ruído

Pré-processamento

Por que pré-processar é importante?



- Os dados do mundo real estão sujos:
 - Incompletos: faltando valores;
 - Ruído: contendo erros ou *outliers*;
 - Inconsistente: Contém discrepâncias;
 - Duplicados: Várias instâncias representando o mesmo objeto.

Nome	Idade	Nascimento	Peso	Salário
João	35	01/01/1987	69,2	R\$ 4,000
	47	08/04/1975	70,1	R\$ 3,500
Marcos		23/09/1979	65,3	R\$ 2,500
Cristina	28	15/09/1983		R\$ 7,000
Lucas			72,7	R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...

Incompleto

Inconsistente

Ruído

Pré-processamento

Por que pré-processar é importante?



- Os dados do mundo real estão sujos:
 - Incompletos: faltando valores;
 - Ruído: contendo erros ou *outliers*;
 - Inconsistente: Contém discrepâncias;
 - Duplicados: Várias instâncias representando o mesmo objeto.

	Nome	Idade	Nascimento	Peso	Salário
Incompleto		35	01/01/1987	69,2	R\$ 4,000
	João	47	08/04/1975	70,1	R\$ 3,500
	Marcos		23/09/1979	65,3	R\$ 2,500
	Cristina	28	15/09/1983		R\$ 7,000
Inconsistente				72,7	R\$ 9,500
Duplicados	Antônio	49	10/03/2010	80,5	R\$ 0,001
	Antônio	49	10/03/2010	80,5	R\$ 0,001
	...	...	...	...	...

Ruído

Pré-processamento

Por que pré-processar é importante?



Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos		23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983		R\$ 7,000
Núbia	57		72,7	R\$ 9,000
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...

Algoritmo de AM ou **Modelo**



- Medida multidimensional da qualidade dos dados:
 - Preciso;
 - Completo;
 - Consistente;
 - Contínuo;
 - Confiável;
 - Mensurável;
 - Interpretável;
 - Acessível.

- Medida multidimensional da qualidade dos dados:
 - Preciso;
 - Completo;
 - Consistente;
 - Contínuo;
 - Confiável;
 - Mensurável;
 - Interpretável;
 - Acessível.

Algoritmo de AM ou **Modelo**




Principais tarefas de pré-processamento

- **Integração:**
 - Integrar múltiplas bases de dados e arquivos;
- **Limpeza:**
 - Preencher de valores faltantes;
 - Suavizar dados ruidosos;
 - Identificação e remoção de erros e ruídos;
 - Resolver inconsistências.
- **Transformação:**
 - Normalização, discretização e codificação.
- **Redução:**
 - Redução ou em número de atributos ou em número de instâncias, ou em ambos.

Integração

- Combina dados de múltiplas fontes.
- Problema de identificação de entidade:
 - Identificar entidades do mundo real de diferentes fontes de dados.
 - Empresa = companhia;
 - Remover dados duplicados e redundantes:
 - Desambiguação;
- Detectar e resolver conflitos de valores de dados:
 - Para a mesma entidade do mundo real, os valores dos atributos são diferentes
 - Diferentes escalas e métricas;
- Quais informações eu devo manter ou considerar?



ID	Attr 1	Attr 2	Attr 3	Attr 4	Attr 5	...
1	1,3	1,5	2,4	3,8	8,7	...
2	4,5	6,8	9,5	1,2	0,8	...
3	3,2	3,5	4,0	1,5	5,1	...
4	...	...	...	...	...	...

Limpeza

- Tarefas de limpeza de dados:
 - Preenchimento de dados faltantes;
 - Identificação de ruídos, suavização e remoção de ruídos;
 - Correção de dados inconsistentes;
 - Eliminar redundância causada por integração.

- Os dados não estão sempre disponíveis.
- Os dados podem ser faltantes por:
 - Mal funcionamento do equipamento de coleta, no caso de sensores;
 - Inconsistência com outro registro e assim, foi deletado;
 - Não fornecido ou duvidoso;
 - ...

Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	
João	47	08/04/1975	70,1	R\$ 3,500
Marcos		23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983		R\$ 7,000
Núbia	57		72,7	R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...

- Como tratar dados faltantes?
 - Fazer preenchimento manual:
 - Cansativo e Inviável

Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos	43	23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983	72,1	R\$ 7,000
Núbia	57			R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...



Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos	43	23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983	72,1	R\$ 7,000
Núbia	57	10/03/1965	72,7	R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...

- Como tratar dados faltantes?
 - Ignorar a instância toda.

Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos	43	23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983	72,1	R\$ 7,000
Núbia	57			R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...



Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos	43	23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983	72,1	R\$ 7,000
X	X	X	X	X
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...

- Como tratar dados faltantes?
 - Ignorar o atributo se estiver faltando para mais de 60% das instâncias.

Nome	Idade	Nascimento	Peso	Salário
Maria	35		69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos	43		65,3	R\$ 2,500
Cristina	38		72,1	R\$ 7,000
Núbia	57		72,7	R\$ 9,500
Antônio	49		80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...





Nome	Idade	Nascimento	Peso	Salário
Maria	35	X	69,2	R\$ 4,000
João	47	X	70,1	R\$ 3,500
Marcos	43	X	65,3	R\$ 2,500
Cristina	38	X	72,1	R\$ 7,000
Núbia	57	X	72,7	R\$ 9,500
Antônio	49	X	80,5	R\$ 0,001
Antônio	49	X	80,5	R\$ 0,001
...	...	...	...	...

- Como tratar dados faltantes?
 - Preenchimento automático usando Média, Mediana e Moda;
 - É muito rápido, mas reduz a variação no conjunto de dados.

Conjunto normalizado

ID	Idade	Tempo de Serviço	Salário
1	0,00	0,00	2000
2	0,17	0,04	2500
3	1,00	1,00	8000
4	0,33	0,35	5000
5	0,23	0,13	3000
6	0,43	0,35	2700
7	0,37	0,48	3,866

- Como tratar dados faltantes?
 - **Em caso de dependência temporal;**
 - Preenchimento automático usando **Interpolação Linear**;
 - https://pandas.pydata.org/pandas-docs/stable/user_guide/missing_data.html.



É basicamente a **renderização de uma linha reta** entre dois ou mais pontos.

- Como tratar dados faltantes?
 - Preenchimento automático usando um algoritmo de AM (método de inferência).

Conjunto normalizado

ID	Idade	Tempo de Serviço	Salário	ED(7,i)
1	0,00	0,00	2000	0,60
2	0,17	0,04	2500	0,47
3	1,00	1,00	8000	0,66
4	0,33	0,35	5000	0,10
5	0,23	0,13	3000	0,70
6	0,43	0,35	2700	0,10
7	0,37	0,48	?	


- k -NN, sendo $k=3$.
- Não é a melhor opção.
- Usar Regressão Linear.

$$\text{Salário} = \frac{2500 + 5000 + 2700}{3} = 3400$$

- Valores com Ruído (*outliers* univariados):
 - Erro randômico ou variância na variável medida;
- Valores incorretos dos dados podem ocorrer devido:
 - Falhas na coleta;
 - Na medição;
 - Na transmissão dos dados;
 - ...


Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos	43	23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983	72,1	R\$ 7,000
Núbia	57	10/03/1965	72,7	R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 0,001
Antônio	49	10/03/2010	80,5	R\$ 0,001
...	...	...	...	...

ID	Nome	Departamento	Salário
1	Ana	RH	3300
2	Bruno	TI	4500
3	Carla	Financeiro	3800
4	Diego	TI	4000
5	Eva	Marketing	4200
6	Fábio	Financeiro	3900
7	Gina	RH	4100
8	Hugo	TI	4300
9	Iris	Marketing	4400
10	João	Financeiro	15000




- Suavização: Método de *Binning* (partição).
- Para suavizar o conjunto: 4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34:
 1. Criar partições (*bin*) de tamanhos iguais (*equi-depth*):
 - **Bin 1:** 4, 8, 9, 15;
 - **Bin 2:** 21, 21, 24, 25;
 - **Bin 3:** 26, 28, 29, 34.
 2. Suavizar:
 - Suavizar pela média:
 - **Bin 1:** 9, 9, 9, 9;
 - **Bin 2:** 23, 23, 23, 23;
 - **Bin 3:** 29, 29, 29, 29.
 - Suavizar pelas extremidades:
 - **Bin 1:** 4, 4, 4, 15;
 - **Bin 2:** 21, 21, 25, 25;
 - **Bin 3:** 26, 26, 26, 34.

- **Ao invés de suavizar eu posso remover** as instâncias que possuem valores *outliers*:
 - Dados que se diferenciam drasticamente de todos os outros;
 - Dados que fogem da normalidade.
- **Porém, outliers nem sempre são ruídos**:
 - Normalmente chove em São Carlos a cada dia 15;
 - Porém, nos últimos 60 dias não choveu.




- *O box plot não detecta ruído diretamente.*
- Ele detecta **valores estatisticamente raros**.
- Depois o analista decide se esses valores são:
 - erro de medição;
 - evento raro legítimo;
 - fenômeno interessante.
- Outliers são detectados estatisticamente, mas decidir se são ruído exige interpretação do domínio.
- Pode ser feita baseado em **análise visual** ou **automática (algorítmica) baseada em quartis**.




- Dados ordenados: [10, 12, 13, 14, 15, 16, 18, 19, 20, 100]
- $Q1 = 13$
- $Q2$ (mediana) = 15.5
- $Q3 = 19$
- $IQR = 6$
- Limite inferior = $Q1 - 1.5 \times IQR = 4.0$
- Limite superior = $Q3 + 1.5 \times IQR = 28.0$
- Outliers detectados = [100]

- Regra: Um valor é considerado outlier se:
 - valor < 4 ;
 - ou
 - valor > 28 .
- Resultado
 - O valor 100 está fora desse intervalo;
 - Portanto:
 - 100 é detectado como outlier.

Colab: Pré-processamento 1.ipynb




- Ruído como uma instância (*outliers* multivariados):
 - A instancia inteira pode ser um *outlier*;
 - Ou seja, o *outlier* pode ser composto por um conjunto de atributos.




- Utilização de algoritmos não supervisionados de agrupamento
- DBSCAN, HDBSCAN


Transformação


- **Normalização:**
 - Colocar os dados dentro de um intervalo específico (em geral pequeno).
- Alguns **algoritmos** de treinamento são **sensíveis a diferenças de escala** entre atributos. Por exemplo, se um atributo é idade de uma pessoa em anos, os valores estarão em uma escala de algumas dezenas mas, se outro atributo for peso em gramas, os valores estarão em uma escala de muitos milhares. Isto pode levar o algoritmo de treinamento a dar mais atenção a peso do que a idade somente devido a escala.



- **Normalização:**
 - Colocar os dados dentro de um intervalo específico (em geral pequeno).
- Alguns **algoritmos** de treinamento são **sensíveis a diferenças de escala** entre atributos. Por exemplo, se um atributo é idade de uma pessoa em anos, os valores estarão em uma escala de algumas dezenas mas, se outro atributo for peso em gramas, os valores estarão em uma escala de muitos milhares. Isto pode levar o algoritmo de treinamento a dar mais atenção a peso do que a idade somente devido a escala.








Considerando os dois atributos 1 e 2

$$ED(x_i, x_j) = \sqrt{(1000 - 100)^2 + (1 - 0.1)^2}$$

$$ED(x_i, x_j) = \sqrt{(900)^2 + (0.9)^2}$$

$$ED(x_i, x_j) \cong 900$$



Considerando os dois atributos 1 e 2

$$ED(x_i, x_j) = \sqrt{(1000 - 100)^2 + (1 - 0.1)^2}$$

$$ED(x_i, x_j) = \sqrt{(900)^2 + (0.9)^2}$$

$$ED(x_i, x_j) \cong 900$$

Considerando o eixo 1

$$ED(x_i, x_j) = \sqrt{(1000 - 100)^2}$$

$$ED(x_i, x_j) \cong 900$$

- Normalização e padronização - Escala de valores:
 - Alguns atributos podem estar em uma escala muito grande, assim se tornando muito mais influente que outros atributos.

$$Z_i = \frac{x_{ik} - \min(X_k)}{\max(X_k) - \min(X_k)} \rightarrow Z_i \in [0, 1]$$

Min-max Cutoff: Normalizar no intervalo [0, 1]
Suscetível a outliers

$$Z_i = \frac{x_{ik} - \mu_{X_k}}{\sigma_{X_k}} \rightarrow E[Z_i] = 0 \text{ e } V(Z_i) = 1$$

Z-score ou Standard Score: Normalizar para atingir
média 0 e variância 1
Valores positivos ou negativos

- Sendo μ_{X_k} média do atributo X_k e σ_{X_k} a variância do atributo X_k .

ID	Idade	Média escolar	Tempo no LOL (m/dia)
1	12	9	110
2	13	9.5	130
3	18	0	135

ID	Idade	Média escolar	Tempo no LOL (m/dia)
1	12	9	110
2	13	9.5	130
3	18	0	135

$$ED(1,2) = \sqrt{(12 - 13)^2 + (9 - 9.5)^2 + (110 - 130)^2} = \sqrt{(-1)^2 + (-0.5)^2 + (-20)^2} = \sqrt{1 + 0.25 + 400} = \sqrt{401.25} = 20.03122$$

$$ED(2,3) = \sqrt{(13 - 18)^2 + (9.5 - 0)^2 + (130 - 135)^2} = \sqrt{(-5)^2 + (9.5)^2 + (-5)^2} = \sqrt{25 + 90.25 + 25} = \sqrt{140.25} = 11.842719$$

ID	Idade	Média escolar	Tempo no LOL (m/dia)
1	12	9	110
2	13	9.5	130
3	18	0	135



$$Z_i = \frac{x_{ik} - \min(X_k)}{\max(X_k) - \min(X_k)} \rightarrow Z_i \in [0,1]$$

ID	Idade	Média escolar	Tempo no LOL (m/dia)
1	0.0	0,94	0.0
2	0.16	1.0	0.8
3	1.0	0.0	1.0


ID	Idade	Média escolar	Tempo no LOL (m/dia)
1	0.0	0,94	0.0
2	0.16	1.0	0.8
3	1.0	0.0	1.0

$$ED(1,2) = \sqrt{(0 - 0.16)^2 + (0.94 - 1)^2 + (0 - 0.8)^2} = \sqrt{(-0.16)^2 + (-0.06)^2 + (-0.8)^2} = \sqrt{0.0256 + 0.0036 + 0.64} = \sqrt{0.6692} = 0.818046$$


$$ED(2,3) = \sqrt{(0.16 - 1)^2 + (1 - 0)^2 + (0.8 - 1)^2} = \sqrt{(-0.84)^2 + (1)^2 + (-0.2)^2} = \sqrt{0.7056 + 1 + 0.04} = \sqrt{1.7456} = 1.321212$$

- Discretização, temos dois tipos:
 - **Atributo quantitativo (numérico) em atributo qualitativo (categórico):**
 - **Dividir uma faixa de atributos contínuos em intervalos (categorias);**
- Para que fazer discretização?
 - **Porque alguns algoritmos de mineração só aceitam ou atributos qualitativos.**
- Algumas técnicas:
 - Métodos de particionamento – *equal-width* (tamanho igual), *equal-frequency* (frequência igual);
 - Métodos baseados em entropia.
 - ...


- Discretizar valores contínuos $\in \mathbb{R}$ em categóricos:
 - Transforma um atributo contínuo em um atributo discreto, mapeando intervalos contínuos em valores discretos.
 - Os valores discretos podem ser valores nominais;




- Discretizar valores contínuos $\in \mathbb{R}$ em categóricos:
 - Transforma um atributo contínuo em um atributo discreto, mapeando intervalos contínuos em valores discretos.
 - Os valores discretos podem ser valores nominais;




Esse é um exemplo abstrato, porém, é possível perceber que os intervalos podem ocasionar alguns erros.



Discretização em intervalos com larguras iguais (ILI)




Discretização em intervalos com frequências iguais (IFI)




Discretização em intervalos baseados em entropia (IBE)


- Discretizar valores contínuos $\in \mathbb{R}$ em categóricos:
 - Transforma um atributo contínuo em um atributo discreto, mapeando intervalos contínuos em valores discretos.
 - Os valores discretos podem ser valores nominais;




Literatura extensa e complexa



Discretização em intervalos com larguras iguais (ILI)



Discretização em intervalos com frequências iguais (IFI)



Discretização em intervalos baseados em entropia (IBE)

- Discretização por intervalos (*binning*).
 - O **binning de largura igual** (*Equi-width binning*) divide o intervalo de valores em intervalos ou compartimentos de tamanho igual.
 - Por exemplo, se os valores variam de 0 a 100 e queremos 10 compartimentos, cada compartimento terá uma largura de 10.
 - Vantagem:
 - Fácil de implementar e interpretar;
 - Preserva a distribuição dos dados.
 - Desvantagem:
 - Pode criar **compartimentos vazios ou esparsos**, especialmente se os dados estiverem distorcidos ou tiverem discrepâncias, podendo reduzir a precisão da análise.
 - Discretizar o conjunto: 0, 4, 12, 16, 16, 24, 26, 28, 30, 50
 - *Equi-width binning*: para o *bin* de tamanho 10:
 - **Bin 1**: 0, 4 = [0, 10];
 - **Bin 2**: 12, 16, 16, 18 = [11, 20];
 - **Bin 3**: 24, 26, 28 = [21, 30];
 - **Bin 4**: Vazio = [31, 40];
 - **Bin 5**: 50 = [41, 50].

- Discretização por intervalos (*binning*).
- O ***binning* de frequência igual** (*Equi-frequency binning*) divide os valores em compartimentos que têm o mesmo número de observações ou frequência.
 - Por exemplo, se tivermos 100 observações e quisermos 10 lixeiras, cada compartimento terá 10 observações.
- Vantagem:
 - Criar compartimentos **balanceados** que podem **lidar melhor com dados distorcidos e outliers**;
- Desvantagem:
 - Pode **distorcer a distribuição dos dados** e criar larguras de compartimento irregulares, podendo tornar a análise mais complexa e menos intuitiva.
- Discretizar o conjunto: 0, 4, 12, 16, 24, 26, 28, 30, 50
 - *Equi-frequency binning*: para o *bin* com densidade de 3:
 - **Bin 1**: 0, 4, 12 = [0, 12];
 - **Bin 2**: 16, 24, 26 = [16, 26];
 - **Bin 3**: 28, 30, 50 = [28, 50].

- Discretização, temos dois tipos:
 - **Atributo qualitativo (categórico) em atributo quantitativo (numérico):**
 - **Mapear atributos categóricos para atributos numéricos.**
- Para que fazer discretização?
 - **Porque alguns algoritmos de mineração só aceitam ou atributos quantitativos.**
- Algumas técnicas:
 - Métodos de particionamento – *equal-width* (tamanho igual), *equal-frequency* (frequência igual);
 - Métodos baseados em entropia.
 - ...

- Transformar atributo nominal em binário (numérico):
 - Atributos nominais podem ser transformados em atributos binários assimétricos;
 - **Criar um atributo binário para cada um dos M estados (ou valores) de um atributo nominal;**
 - O valor do atributo representando o estado é definido em 1 e os demais valores são definidos em 0.

Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

- Transformar atributo nominal em binário (numérico):
 - Atributos nominais podem ser transformados em atributos binários assimétricos;
 - **Criar um atributo binário para cada um dos M estados (ou valores) de um atributo nominal;**
 - O valor do atributo representando o estado é definido em 1 e os demais valores são definidos em 0.



Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Verde	Vermelho	Azul	Cinza
Verde	1	0	0	0
Vermelho	0	1	0	0
Azul	0	0	1	0
Cinza	0	0	0	1

- Transformar atributo nominal em binário (numérico):
 - Atributos nominais podem ser transformados em atributos binários assimétricos;
 - Criar um atributo binário para cada um dos M estados (ou valores) de um atributo nominal;**
 - O valor do atributo representando o estado é definido em 1 e os demais valores são definidos em 0.



Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza



Cor	Verde	Vermelho	Azul	Cinza
Verde	1	0	0	0
Vermelho	0	1	0	0
Azul	0	0	1	0
Cinza	0	0	0	1

Pessoa	Verde	Vermelho	Azul	Cinza
João	1	0	0	0
Marcelo	0	1	0	0
Maria	0	1	0	0
Marcia	0	0	1	0
Pedro	0	0	0	1

• Transf

- A
- C
- C

One Hot Encoding

- Conhecido como vetor binário.
- Você pode utilizar alguma medida de distância específica para esse caso, como a medida *coseno*.

Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Verde	Vermelho	Azul	Cinza
Verde	1	0	0	0
Vermelho	0	1	0	0
Azul	0	0	1	0
Cinza	0	0	0	1

Pessoa	Verde	Vermelho	Azul	Cinza
João	1	0	0	0
Marcelo	0	1	0	0
Maria	0	1	0	0
Marcia	0	0	1	0
Pedro	0	0	0	1

• Transf

• A

• C

• C

One Hot Encoding

- Um problema é que se você tiver muitos valores nominais, você terá muitas colunas.
- Isso causa um problema conhecido com a “maldição da dimensionalidade”.

Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Verde	Vermelho	Azul	Cinza
Verde	1	0	0	0
Vermelho	0	1	0	0
Azul	0	0	1	0
Cinza	0	0	0	1

Pessoa	Verde	Vermelho	Azul	Cinza
João	1	0	0	0
Marcelo	0	1	0	0
Maria	0	1	0	0
Marcia	0	0	1	0
Pedro	0	0	0	1

Label Encoder

- Você pode simplesmente gerar um código crescente para cada cor.
- Entretanto, essa abordagem não é muito utilizada.
- O valor do atributo representando o estado é definido em 1 e os demais em 0.



Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Código
Verde	1
Vermelho	2
Azul	3
Cinza	4

Pessoa	Código
João	1
Marcelo	2
Maria	2
Marcia	3
Pedro	4

Label Encoder

- Ao aplicar essa lógica, o **modelo pode interpretar uma classe mais importante que as outras** e isso pode enviesar a predição do modelo. Por exemplo, uma “Verde” recebe valor 1 no *Label Encoder*, enquanto uma “Cinza” recebe o valor 4. A modelagem pode interpretar a “Cinza” como superior à “Verde”, pois $4 > 1$.



Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Código
Verde	1
Vermelho	2
Azul	3
Cinza	4

Pessoa	Código
João	1
Marcelo	2
Maria	2
Marcia	3
Pedro	4

Label Encoder

- Ao transformar um atributo categórico sem ordem (nominal) em valores numéricos numa escala de 1 a 10, você está introduzindo artificialmente uma ordem onde não existe originalmente.
- O valor do atributo representando o estado é definido em 1 e os demais em 0.

Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Código
Verde	1
Vermelho	2
Azul	3
Cinza	4

Pessoa	Código
João	1
Marcelo	2
Maria	2
Marcia	3
Pedro	4

Label Encoder

- Se o atributo original representa cores: vermelho, azul, verde, amarelo, e você os codifica como 1, 2, 3, 4, o modelo pode entender que “azul” (2) está mais próximo de “verde” (3) do que de “vermelho” (1), o que não tem significado real.



Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Código
Verde	1
Vermelho	2
Azul	3
Cinza	4

Pessoa	Código
João	1
Marcelo	2
Maria	2
Marcia	3
Pedro	4

- Transformar atributo nominal em binário (numérico):
 - Atributos nominais podem ser transformados em atributos binários assimétricos;
 - Criar um atributo binário para cada um dos M estados (ou valores) de um atributo nominal;**

Uma solução é quebrar esse atributo binário em colunas e evitar esse viés.
Entretanto, nesse caso, você volta ao *One Hot Encoding*.

Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Código
Verde	1
Vermelho	2
Azul	3
Cinza	4

Cor	Código			
Verde	1	0	0	1
Vermelho	2	0	1	0
Azul	3	0	1	1
Cinza	4	1	0	0

Pessoa	Att1	Att2	Att3
João	0	0	1
Marcelo	0	1	0
Maria	0	1	0
Marcia	0	1	1
Pedro	1	0	0

- Outra solução é concatenar os valores binários em um único atributo.
- Ao concatenar essas colunas em uma única coluna binária, você pode estar querendo dizer algo como formar uma representação binária única.
- Entretanto, isso também pode gerar algum viés de “dominância” para o algoritmo e o algoritmo pode interpretar ordem ou dominância onde não há.

Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

Cor	Verde	Vermelho	Azul	Cinza
Verde	1	0	0	0
Vermelho	0	1	0	0
Azul	0	0	1	0
Cinza	0	0	0	1

Pessoa	Código
João	1000
Marcelo	0100
Maria	0100
Marcia	0010
Pedro	0001

Recomendações:

- Para atributos nominais, a codificação correta é geralmente:
 - *One-Hot Encoding*: Cria uma nova coluna binária para cada categoria (usado para algoritmos que se beneficiam de entrada vetorial, como Redes Neurais ou SVMs).
 - *Label Encoding* (com cautela): Só se for garantido que o algoritmo não vai assumir ordem (por exemplo, Árvores de Decisão são mais tolerantes a isso).
- Se você estiver usando essa escala de 1 a 10 por alguma razão específica (ex: reduzir dimensionalidade), pode ser válido, mas com risco de viés de interpretação por parte do algoritmo.

Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

- Transformar atributo nominal em binário (numérico):
 - Atributos nominais podem ser transformados em atributos binários assimétricos;

Se você está tentando reduzir a dimensionalidade, outras técnicas que preservam a natureza nominal do dado são:

- *Embeddings* aprendidos (em modelos como redes neurais).
- Codificações baseadas em frequência ou impacto (*target encoding*) – com cautela.

Pessoa	Cor Favorita
João	Verde
Marcelo	Vermelho
Maria	Vermelho
Marcia	Azul
Pedro	Cinza

- Como converter um atributo **qualitativo ordinal** em atributo quantitativo numérico?
 - Utilizar as estratégias anteriores;
 - Mas ...

- As estratégias anteriores não levam em consideração a ordem dos elementos

- Ordinal Encoding
- Seja M_f o número de estados que um atributo f ordinal pode ter;
- Os estados ordenados definem o *ranking* $1 \dots M_f$;
- O valor de f para o i -ésimo exemplo é x_{if} , e f possui M_f estados ordenados, representando o *ranking* $1 \dots M_f$.
- Passos:
 1. Substitua x_{if} por sua posição correspondente no *ranking* r_{if} ;
 2. Uma vez que cada atributo pode ter um número diferente de estados, é necessário mapear o intervalo de valores de cada atributo em $[0, 1]$ para que cada atributo tenha um peso igual;

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

Ranking do atributo

Número de estados

ID	Altura	Escolaridade
1	Médio	Superior
2	Baixo	Médio
3	Alto	Superior

ID	Altura	Escolaridade
1	Médio	Superior
2	Baixo	Médio
3	Alto	Superior

$$M_f = 3 \quad M_f = 2$$



ID	Altura	Escolaridade
1	Médio	Superior
2	Baixo	Médio
3	Alto	Superior

$M_f = 3$ $M_f = 2$

ID	Altura	Escolaridade
1		
2		
3		

Ranking



ID	Altura	Escolaridade
1	Médio	Superior
2	Baixo	Médio
3	Alto	Superior

 $M_f = 3$ $M_f = 2$

ID	Altura	Escolaridade
1	2	2
2	1	1
3	3	2

Ranking



ID	Altura	Escolaridade
1	Médio	Superior
2	Baixo	Médio
3	Alto	Superior

$M_f = 3$ $M_f = 2$

ID	Altura	Escolaridade
1	2	2
2	1	1
3	3	2

Ranking


$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

ID	Altura	Escolaridade
1		
2		
3		

ID	Altura	Escolaridade
1	Médio	Superior
2	Baixo	Médio
3	Alto	Superior

$$M_f = 3 \quad M_f = 2$$



ID	Altura	Escolaridade
1	2	2
2	1	1
3	3	2

Ranking

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

ID	Altura	Escolaridade
1	$\frac{2 - 1}{3 - 1}$	$\frac{2 - 1}{2 - 1}$
2	$\frac{1 - 1}{3 - 1}$	$\frac{1 - 1}{2 - 1}$
3	$\frac{3 - 1}{3 - 1}$	$\frac{2 - 1}{2 - 1}$

ID	Altura	Escolaridade
1	Médio	Superior
2	Baixo	Médio
3	Alto	Superior

$M_f = 3$ $M_f = 2$

ID	Altura	Escolaridade
1	2	2
2	1	1
3	3	2

Ranking

ID	Altura	Escolaridade
1		
2		
3		

Tabela Final

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

ID	Altura	Escolaridade
1	$\frac{2 - 1}{3 - 1}$	$\frac{2 - 1}{2 - 1}$
2	$\frac{1 - 1}{3 - 1}$	$\frac{1 - 1}{2 - 1}$
3	$\frac{3 - 1}{3 - 1}$	$\frac{2 - 1}{2 - 1}$

Pré-processamento

Transformação: Codificação (qualitativo → quantitativo)



ID	Altura	Escolaridade
1	Médio	Superior
2	Baixo	Médio
3	Alto	Superior

$M_f = 3$ $M_f = 2$

ID	Altura	Escolaridade
1	2	2
2	1	1
3	3	2

Ranking

ID	Altura	Escolaridade
1	0,5	1
2	0,0	0
3	1,0	1

Tabela Final

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

ID	Altura	Escolaridade
1	$\frac{2 - 1}{3 - 1}$	$\frac{2 - 1}{2 - 1}$
2	$\frac{1 - 1}{3 - 1}$	$\frac{1 - 1}{2 - 1}$
3	$\frac{3 - 1}{3 - 1}$	$\frac{2 - 1}{2 - 1}$


Redução

- A quantidade de dados é muito grande para lidar.
- O tamanho de um problema de mineração refere-se a:
 - Número de atributos;
 - Número de instâncias.
- A eficiência de uma solução depende em muitos casos do tamanho do problema.
- O tamanho de um problema interfere na:
 - Qualidade das respostas dos algoritmos;
 - No custo do aprendizado.

Redução de dados

Obter uma representação do conjunto de dados que é muito menor em volume e produz o mesmo (ideal) ou quase o mesmo resultado ao ser analisado.

- **Redução de dimensionalidade:**
 - Diminuição no número de atributos:
 - Seleção de características (atributos);
 - Transformação de características (atributos).
- **Agregação e agrupamento:**
 - Criação de conjuntos menores para serem analisados.
- **Amostragem.**



Redução do número de atributos

- **Espera-se que todos os atributos sejam relevantes, porém nem sempre é possível garantir isso.**
- Alguns atributos são redundantes e assim poderiam ser eliminados.
- Muitos atributos aumentam o custo computacional do aprendizado.
- Maldição da dimensionalidade: Aumentar a precisão do algoritmo.
- Interpretabilidade: Gerar modelos compactos mais fáceis de interpretar.

Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos	43	23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983	72,1	R\$ 7,000
Núbia	57	10/03/1965	72,7	R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 3,000
...	...	...	...	...

Redução do número de atributos

- Espera-se que todos os atributos sejam relevantes, porém nem sempre é possível garantir isso.
- **Alguns atributos são redundantes e assim poderiam ser eliminados.**
- Muitos atributos aumentam o custo computacional do aprendizado.
- Maldição da dimensionalidade: Aumentar a precisão do algoritmo.
- Interpretabilidade: Gerar modelos compactos mais fáceis de interpretar.

Nome	Idade	Nascimento	Peso	Salário
Maria	35	01/01/1987	69,2	R\$ 4,000
João	47	08/04/1975	70,1	R\$ 3,500
Marcos	43	23/09/1979	65,3	R\$ 2,500
Cristina	38	15/09/1983	72,1	R\$ 7,000
Núbia	57	10/03/1965	72,7	R\$ 9,500
Antônio	49	10/03/2010	80,5	R\$ 3,000
...	...	...	...	...



Redução do número de atributos

- Espera-se que todos os atributos sejam relevantes, porém nem sempre é possível garantir isso.
- Alguns atributos são redundantes e assim poderiam ser eliminados.
- **Muitos atributos aumentam o custo computacional do aprendizado.**
- Maldição da dimensionalidade: Aumentar a precisão do algoritmo.
- Interpretabilidade: Gerar modelos compactos mais fáceis de interpretar.

- Algoritmos simples dependem do número de atributos.
- Complexidade do k -NN:
 - Seja $|X|$ o número de exemplos de treinamento e $|X_m|$ o número de atributos, a complexidade do k -NN é $O(|X| \times |X_m|)$.

Redução do número de atributos

- Espera-se que todos os atributos sejam relevantes, porém nem sempre é possível garantir isso.
- Alguns atributos são redundantes e assim poderiam ser eliminados.
- Muitos atributos aumentam o custo computacional do aprendizado.
- **Maldição da dimensionalidade: Aumentar a precisão do algoritmo.**
- Interpretabilidade: Gerar modelos compactos mais fáceis de interpretar.




Bellman R.E. Adaptive Control Processes. Princeton University Press, Princeton, NJ, 1961

Redução do número de atributos

- Espera-se que todos os atributos sejam relevantes, porém nem sempre é possível garantir isso.
- Alguns atributos são redundantes e assim poderiam ser eliminados.
- Muitos atributos aumentam o custo computacional do aprendizado.
- **Maldição da dimensionalidade: Aumentar a precisão do algoritmo.**
- Interpretabilidade: Gerar modelos compactos mais fáceis de interpretar.

- De modo geral, o desempenho de um classificador tende a se degradar a partir de um determinado n° de atributos




Hughes, G.F. (January 1968). "On the mean accuracy of statistical pattern recognizers". IEEE Transactions on Information Theory. 14 (1): 55–63

A beginner's guide to dimensionality reduction in Machine Learning: <https://towardsdatascience.com/dimensionality-reduction-for-machine-learning-80a46c2ebb7e>

Redução de dimensionalidade

- Esperança de que a distância seja mais descritiva.
- Alguns algoritmos não lidam bem com alta dimensionalidade.
- Muitas vezes, a redução de dimensionalidade é necessária para melhorar a performance dos modelos.
- **Maldição da dimensionalidade**: À medida que a quantidade de dimensões aumenta, a distância entre vários pontos de dados também aumenta. É por isso que você precisa de uma quantidade maior de pontos para cobrir mais espaço, na esperança de que a distância seja mais descritiva.
- Interpretabilidade: Gerar modelos mais fáceis de interpretar.

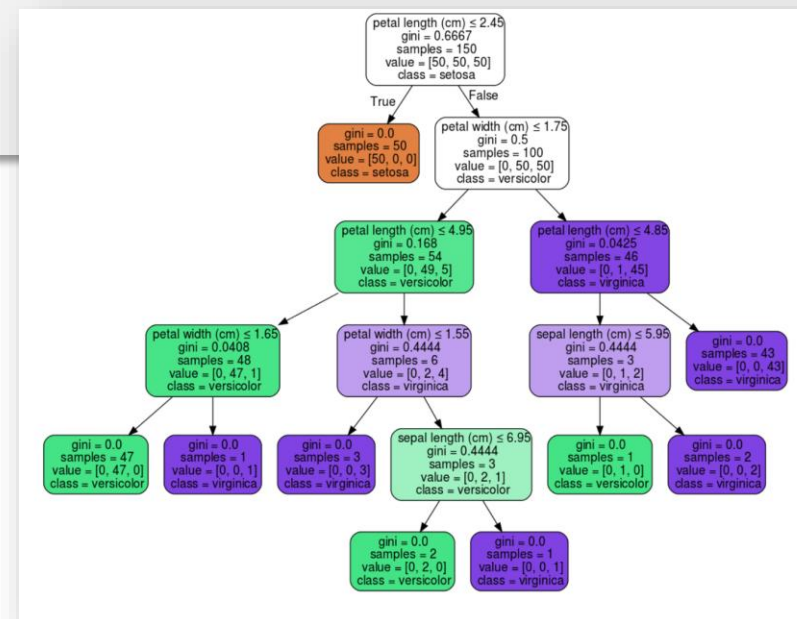
- De modo geral, o desempenho de um classificador tende a se degradar a partir de um determinado n° de atributos



Hughes, G.F. (January 1968). "On the mean accuracy of statistical pattern recognizers". IEEE Transactions on Information Theory. 14 (1): 55–63
A beginner's guide to dimensionality reduction in Machine Learning: <https://towardsdatascience.com/dimensionality-reduction-for-machine-learning-80a46c2ebb7e>

Redução do número de atributos

- Espera-se que todos os atributos sejam relevantes, porém nem sempre é possível garantir isso.
- Alguns atributos são redundantes e assim poderiam ser eliminados.
- Muitos atributos aumentam o custo computacional do aprendizado.
- Maldição da dimensionalidade: Aumentar a precisão do algoritmo.
- **Interpretabilidade: Gerar modelos compactos mais fáceis de interpretar.**



<https://medium.com/intel-student-ambassadors/interpretable-machine-learning-with-decision-tree-based-models-ae78245dc506>


Seleção de atributos

- Escolha de um subconjunto de atributos relevantes dentre os atributos disponíveis:
 - Filtros;
 - *Wrappers*.


Filtro

- Atributos são ordenados com base em métricas de relevância:
 - Retorna os atributos mais bem ordenados.
- Descartam atributos irrelevantes antes do processo de aprendizado.
- Independente do algoritmo.
- Diferentes métricas podem ser usadas para definir relevância de atributos:
 - Retorna os k atributos mais relevantes;
 - Selecionar os k atributos com maior correlação com o atributo de classe;
 - Atributos com maior variância;
 - Atributos que tem correlação alta com o atributo classe;
 - Pares de atributos que são altamente correlacionados eu posso descartar um deles.

- *Heatmap* para um conjunto de dados de preços de habitação em Boston usando a correlação de *Pearson*.



- *Heatmap* para um conjunto de dados de preços de habitação em Boston usando a correlação de *Pearson*.




```
target = abs(cor["MEDV"])  
# Selecting highly correlated features  
relevant_features = target[target > 0.5]
```

RM	0.70
PTRATIO	0.51
LSTAT	0.74
MEDV	1.00

- Seleciona os atributos com maior correlação com a classe.

- *Heatmap* para um conjunto de dados de preços de habitação em Boston usando a correlação de *Pearson*.



```
target = abs(cor["MEDV"])
# Selecting highly correlated features
relevant_features = target[target > 0.5]
```

RM	0.70
PTRATIO	0.51
LSTAT	0.74
MEDV	1.00

- Seleciona os atributos com maior correlação com a classe.

	RM	LSTAT
RM X	1.00	-0.61
LSTAT	-0.61	1.00

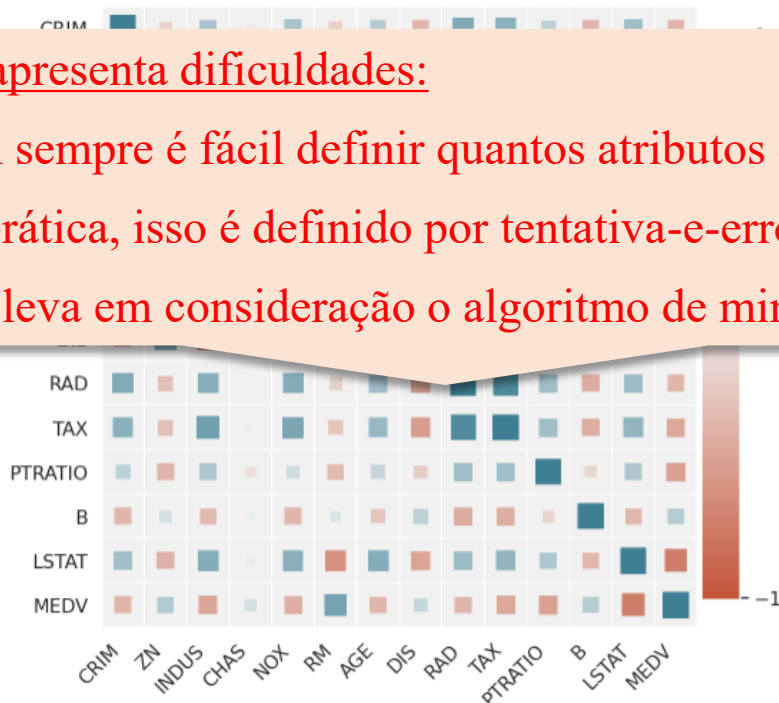
	LSTAT	PTRATIO
LSTAT	1.00	0.37
PTRATIO	0.37	1.00

- Pares com alta correlação, descartar o que possui menor correlação com a classe.

- *Heatmap* para um conjunto de dados de preços de habitação em Boston usando a correlação de *Pearson*.

Porém apresenta dificuldades:

- Nem sempre é fácil definir quantos atributos descartar.
- Na prática, isso é definido por tentativa-e-erro.
- Não leva em consideração o algoritmo de mineração a ser posteriormente utilizado.



RM	0.70
PTRATIO	0.51
LSTAT	0.74
MEDV	1.00

- Seleciona os atributos com maior correlação com a classe.


	RM	LSTAT
RM ✖	1.00	-0.61
LSTAT	-0.61	1.00

	LSTAT	PTRATIO
LSTAT	1.00	0.37
PTRATIO	0.37	1.00

- Pares com alta correlação, descartar o que possui menor correlação com a classe.



Wrappers

- Realizam, de fato, uma **busca no espaço de subconjuntos de atributos**.
- Busca exaustiva não é realizada na prática.
- São vantajosos em relação aos filtros por considerarem o algoritmo em questão.



Redução de atributos

- Criação de novos atributos a partir da combinação dos atributos existentes.
- Redução de dimensionalidade: PCA (*Principal Component Analysis*).
- Gera um **novo** conjunto de atributos compacto.
- Perde o poder de entendimento do atributo.
- Depois de transformado o atributo perde o seu significado.





Redução do número de instâncias

- Diferente do número de atributos, conforme o número de instâncias aumenta a acurácia do algoritmo de AM também aumenta:
 - Aumenta o número de casos cobertos pelo conjunto de dados.
- Porém, considerando o advento do *Big Data*, poder de processamento e memória se tornou uma questão complexa.

<https://medium.com/intel-student-ambassadors/interpretable-machine-learning-with-decision-tree-based-models-ae78245dc506>

- Utilizar amostragem:
 - Escolha de um subconjunto representativo dos dados.




Randômica:

- Uma amostragem randômica pode ser muito pouco efetiva na presença de tendência (viés).

Amostragem estratificada:

- Aproximar a porcentagem de cada classe (ou da subpopulação de interesse) na base de dados completa.

- Agrupamento:
 - Agrupar as instâncias em pequenos conjuntos e processá-los separadamente.




Conjunto de instâncias processado de forma isolada.

- A preparação dos dados é um grande problema para a mineração de dados, que inclui:
 - Limpeza de dados;
 - Integração de dados;
 - Transformação;
 - Redução de dados;
 - Discretização.
- Muitos métodos têm sido propostos, mas ainda é uma área ativa de pesquisa.
- Pré-processamento é a parte de maior custo, em termos de tempo, de um projeto de mineração de dados




- Análise Exploratória de Dados (AED - *Exploratory Data Analysis*)
 - Examinar os dados previamente à aplicação de qualquer técnica de AM
 - Auxilia a tomar decisões em relação a construção dos modelos
 - Consegue um entendimento básico de seus dados e das relações existentes entre as variáveis analisadas


Histograma




Boxplot




Violin plot





PairPlot



Heatmap





- Aprendizado supervisionado e a tarefa de classificação

Obrigado

Dúvidas

Email: alanvalejo@ufscar.br