

Universidade Federal de São Carlos - UFSCar
Departamento de Computação - DC
CEP 13565-905, Rod. Washington Luiz, s/n, São Carlos, SP

Aula 07 – Naïve Bayes

Prof. Dr. Alan Demétrius Baria Valejo

1001524 - Aprendizado de Máquina 1

- Definições
- Introdução
- Teoria da Decisão Bayesiana (Teorema de Bayes)
- Classificador *Naïve Bayes*
- Exemplos
- Problema da frequência zero
- Valores contínuos
- Valores ausentes
- Considerações finais
- Exemplos Scikit-learn
- Próxima aula

Definições

- Considere um conjunto de dados $X = \{x_1, x_2, x_3, \dots, x_n\}$, onde n indica o número de exemplos (linhas da tabela).
- Cada exemplo x_i possui m atributos, seja, o vetor de característica de tamanho m , tal que, $x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{im})$.
- **x_{ij} indica o valor do atributo j no exemplo i .**
- Seja Y um conjunto de classes com k classes, ou seja, $Y = \{y_1, y_2, y_3, \dots, y_k\}$.

		Atributo x_{im} ou X_m ou classe						
		Atributo X_j ou $x^{(j)}$						
		Id	Att 1	Att 2	Att 3	Att 4	...	Att m
$X =$	Exemplo x_1	x_1	x_{11}	x_{12}	x_{13}	x_{14}	...	x_{1m}
		x_2	x_{21}	x_{22}	x_{23}	x_{24}	...	x_{1m}
		...	...	...	...	...	...	...
	Exemplo x_n	x_n	x_{n1}	x_{n2}	x_{n3}	x_{n4}	...	x_{nm}

- Considere um conjunto de dados $X = \{x_1, x_2, x_3, \dots, x_n\}$, onde n indica o número de exemplos (linhas da tabela).
- Cada exemplo x_i possui m atributos, seja, o vetor de característica de tamanho m , tal que, $x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{im})$.
- **x_{ij} indica o valor do atributo j no exemplo i .**
- Seja Y um conjunto de classes com k classes, ou seja, $Y = \{y_1, y_2, y_3, \dots, y_k\}$.

- $X \in \mathbb{R}^{n \times m}$, portanto:
 - $X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$
- $x_i \in \mathbb{R}^m \rightarrow$ um exemplo.
- $X_j \in \mathbb{R}^n \rightarrow$ atributo j (vetor), portanto:
 - $X_j = \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix}$
- $x_{ij} \in \mathbb{R} \rightarrow$ valor.
- Linha = exemplo $\rightarrow x_i$.
- Coluna = atributo $\rightarrow X_j$.
- Célula = valor $\rightarrow x_{ij}$.

- **Insight importante:**
 - **Extremamente comum em livros e slides**, porque:
 - Em probabilidade: X costuma ser variável aleatória;
 - Em ML: X costuma ser o conjunto de dados;
 - Dois “dialetos” diferentes colidindo.
- Outras notações ao longo da disciplina:
 - x : variável genérica (mais geral);
 - x_i : mostra específica (mais concreto).

- Considere um conjunto de dados $X = \{x_1, x_2, x_3, \dots, x_n\}$, onde n indica o número de exemplos (linhas da tabela).
 - Cada exemplo x_i possui m atributos, seja, o vetor de característica de tamanho m , tal que, $x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{im})$.
 - **x_{ij} indica o valor do atributo j no exemplo i .**
 - Seja Y um conjunto de classes com k classes, ou seja, $Y = \{y_1, y_2, y_3, \dots, y_k\}$.
-
- $X \in \mathbb{R}^{n \times m}$, portanto:
 - $X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$
 - $x_i \in \mathbb{R}^m \rightarrow$ um exemplo.
 - $X_j \in \mathbb{R}^n \rightarrow$ atributo j (vetor), portanto:
 - $X_j = \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix}$
 - $x_{ij} \in \mathbb{R} \rightarrow$ valor.
 - Linha = exemplo $\rightarrow x_i$.
 - Coluna = atributo $\rightarrow X_j$.
 - Célula = valor $\rightarrow x_{ij}$.
-
- Aqui estamos usando uma notação abreviada: $P(x_{ij} | y_k)$ na verdade significa $P(X_j = x_{ij} | Y = y_k)$, ou seja:
 - $P(y_k | x_i) \leftrightarrow P(Y = y_k | X = x_i)$;
 - $P(x_i | y_k) \leftrightarrow P(X = x_i | Y = y_k)$;
 - $P(x_{ij} | y_k) \leftrightarrow P(X_j = x_{ij} | Y = y_k)$.
 - Estou usando uma **notação abreviada padrão em ML**, onde:
 - y_k : já representa o evento $Y = y_k$;
 - x_i : já representa o evento $X = x_i$.
 - Em aprendizado de máquina, omitimos o '=' por simplicidade. Mas formalmente estamos condicionando em eventos, não em valores soltos.
 - x_i : Este é um exemplo específico.
 - y_k : Usado quando eu quero testar todas as possíveis respostas ou classes.
 - y_i : Classe do exemplo x_i .

Introdução

- É um dos classificadores probabilísticos mais simples.
- Baseado no teorema de *Bayes*, cujo autor é Thomas *Bayes*, que descreve a probabilidade de ocorrer um evento, baseado em um conhecimento a priori que pode estar relacionado ao evento.
- Chamado de “*naïve*” (ingênuo, ou simples) porque assume que a probabilidade de ocorrer cada valor de atributo em uma dada classe é independente dos valores dos outros atributos.
- Simplifica os cálculos utilizados para computar as probabilidades.

- Probabilidade de ocorrer um evento baseado no conhecimento a priori que pode estar relacionado ao evento.
- Um evento A, dado um evento B, não depende apenas da relação entre A e B, mas também da probabilidade de observar-se A independentemente de observar-se B.

Mitchell (1997, apud Faceli et al., 2011)

1701 - 1761
Nota histórica
1763



- É um dos classificadores probabilísticos mais simples.
- Baseado no teorema de *Bayes*, cujo autor é Thomas *Bayes*, que descreve a probabilidade de ocorrer um evento, baseado em um conhecimento a priori que pode estar relacionado ao evento.
- Chamado de “*naïve*” (ingênuo, ou simples) porque assume que a probabilidade de ocorrer cada valor de atributo em uma dada classe é independente dos valores dos outros atributos.
- Simplifica os cálculos utilizados para computar as probabilidades.

- Probabilidade de ocorrer um evento baseado no conhecimento a priori que pode estar relacionado ao evento.
- Um evento A, dado um evento B, não depende apenas da relação entre A e B, mas também da probabilidade de observar-se A independentemente de observar-se B.

Mitchell (1997, apud Faceli et al., 2011)

1701 - 1761
Nota histórica
1763



- É um dos classificadores probabilísticos mais simples.
- Baseado no teorema de *Bayes*, cujo autor é Thomas *Bayes*, que **descreve a probabilidade de ocorrer um evento, baseado em um conhecimento a priori** que pode estar relacionado ao evento.
- Chamado de “*naïve*” (ingênuo, ou simples) porque assume que a probabilidade de ocorrer cada valor de atributo em uma dada classe é independente dos valores dos outros atributos.
- Simplifica os cálculos utilizados para computar as probabilidades.

- **Probabilidade de ocorrer um evento baseado no conhecimento a priori** que pode estar relacionado ao evento.
- Um evento A, dado um evento B, não depende apenas da relação entre A e B, mas também da probabilidade de observar-se A independentemente de observar-se B.

Mitchell (1997, apud Faceli et al., 2011)

1701 - 1761
Nota histórica
1763



- É um dos classificadores probabilísticos mais simples.
- Baseado no teorema de *Bayes*, cujo autor é Thomas *Bayes*, que descreve a probabilidade de ocorrer um evento, baseado em um conhecimento a priori que pode estar relacionado ao evento.
- Chamado de “*naïve*” (ingênuo, ou simples) porque **assume que a probabilidade de ocorrer cada valor de atributo em uma dada classe é independente dos valores dos outros atributos.**
- Simplifica os cálculos utilizados para computar as probabilidades.

- Probabilidade de ocorrer um evento baseado no conhecimento a priori que pode estar relacionado ao evento.
- Um evento A, dado um evento B, não depende apenas da relação entre A e B, mas também da probabilidade de observar-se A independentemente de observar-se B.

Mitchell (1997, apud Faceli et al., 2011)

1701 - 1761
Nota histórica
1763



- É um dos classificadores probabilísticos mais simples.
- Baseado no teorema de *Bayes*, cujo autor é Thomas *Bayes*, que descreve a probabilidade de ocorrer um evento, baseado em um conhecimento a priori que pode estar relacionado ao evento.
- Chamado de “*naïve*” (ingênuo, ou simples) porque assume que a probabilidade de ocorrer cada valor de atributo em uma dada classe é independente dos valores dos outros atributos.
- **Simplifica os cálculos utilizados para computar as probabilidades.**

- Probabilidade de ocorrer um evento baseado no conhecimento a priori que pode estar relacionado ao evento.
- Um evento A, dado um evento B, não depende apenas da relação entre A e B, mas também da probabilidade de observar-se A independentemente de observar-se B.

Mitchell (1997, apud Faceli et al., 2011)

1701 - 1761
Nota histórica
1763




- Origem do *Naive Bayes* (versão original):
 - O **Teorema de Bayes** é antigo e vem do trabalho de **Thomas Bayes**, publicado postumamente por Richard Price:
 - **Título:** *An Essay towards solving a Problem in the Doctrine of Chances*;
 - **Autor:** Thomas Bayes (publicado por Richard Price);
 - **Ano:** 1763.
 - **Link:** <https://doi.org/10.1098/rstl.1763.0053>
 - No entanto, o “**Naive**” *Bayes* (com a suposição de independência entre atributos) **não tem um único artigo fundador**.
 - Em vez disso, ele **emergiu como uma heurística** ao longo dos anos, sendo usado de forma empírica na década de **1950** e **1960**, especialmente em sistemas de classificação automática de texto e documentos.
 - **Um dos primeiros usos notáveis foi por Maron e Kuhns (1960):**
 - Título: *On relevance, probabilistic indexing and information retrieval*;
 - Autores: M.E. Maron e J.L. Kuhns;
 - Ano: 1960;
 - Revista: *Journal of the ACM*;
 - Link: <https://dl.acm.org/doi/10.1145/321033.321035>;
 - Este artigo aplicou o teorema de *Bayes* à indexação de documentos, e pode ser visto como um dos **ancestrais diretos** do *Naive Bayes* moderno.

- **Naive Bayes com distribuição Gaussiana (atributos contínuos):**
 - O uso da **distribuição normal (gaussiana)** para modelar atributos contínuos também não tem um único artigo original.
 - Ele foi introduzido de forma natural por analogia com variáveis contínuas:
 - A ideia é:
 - Se a variável x_j for contínua, modela-se $P(x_j|c_i)$ com uma distribuição de probabilidade, e a mais simples e comum é a normal (gaussiana).
 - A aplicação prática disso ganhou popularidade nos anos 1990, com sistemas de classificação baseados em probabilidade.
 - Um artigo frequentemente citado que formaliza e populariza o *Naive Bayes* em diferentes contextos, incluindo atributos contínuos, é:
 - Título: *A Comparison of Event Models for Naive Bayes Text Classification*;
 - Autor: Andrew McCallum & Kamal Nigam;
 - Ano: 1998;
 - Link: <https://aaai.org/papers/041-ws98-05-007/>.


Teoria da Decisão Bayesiana (Teorema de *Bayes*)

Uma fabrica que produz processadores perfeitos e com defeito.




Dados a priori
Experiência.


95% Perfeitas



05% Com defeito




Uma fabrica que produz processadores perfeitos e com defeito.



Novo processador
Perfeito?
Defeito?

Uma fabrica que produz processadores perfeitos e com defeito.




Senso comum
Classificar como perfeita.

A teoria *bayesiana* formaliza o senso comum e classifica meu objeto na classe como mais provável.


Novo processador
Perfeito?
Defeito?

- $P(y_1|X)$: Probabilidade de observação com atributos X pertencer a classe y_1 .
- $P(y_2|X)$: Probabilidade de observação com atributos X pertencer a classe y_2 .




- $P(y_1|X)$: Probabilidade de observação com atributos X pertencer a classe y_1 .
- $P(y_2|X)$: Probabilidade de observação com atributos X pertencer a classe y_2 .


Probabilidade condicional a posteriori:
Qual a probabilidade da classe y_2 acontecer
dado que eu observei X ?



- Se $P(y_1|X) > P(y_2|X)$ então $X \in y_1$.
- Se $P(y_1|X) < P(y_2|X)$ então $X \in y_2$.



- Se $P(y_1|X) > P(y_2|X)$ então $X \in y_1$.
- Se $P(y_1|X) < P(y_2|X)$ então $X \in y_2$.



$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

- Essa parte vem do conjunto de treinamento.
- Eventos que eu sei calcular.

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

- Essa parte que quero calcular.

- **Probabilidade de B acontecer, dado que A aconteceu.**
- É a chance do teste dar positivo (B) se a pessoa realmente estiver doente (A). Isso costuma ser conhecido — por exemplo, a sensibilidade de um teste.

- **Probabilidade de A acontecer, sem saber nada sobre B.**
- É a probabilidade a priori.
- No exemplo da doença, é a proporção de pessoas doentes na população.

- **Probabilidade de A acontecer, dado que B aconteceu.**
- É o que queremos calcular. Por exemplo, a chance de uma pessoa estar doente (A), dado que o teste deu positivo (B).

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

- **Probabilidade de B acontecer, independentemente de A.**
- É a chance do teste dar positivo para qualquer pessoa, doente ou não.

- Por que multiplicamos $P(A)$ por $P(B|A)$?
 - Porque $P(A \cap B)$ — ou seja, a probabilidade de A e B acontecerem ao mesmo tempo — pode ser calculada assim:

$$P(A \cap B) = P(A) \times P(B|A) = P(B) \times P(A|B)$$

- Essas expressões são **formas equivalentes** de escrever a mesma coisa: a chance de A e B acontecerem juntos.
- Intuição:
 - Você pode pensar assim:
 - $P(A)$: Qual a chance de A acontecer?
 - $P(B|A)$: Se A aconteceu, qual a chance de também vermos B?
 - **Juntas, essas duas informações nos dizem com que frequência esperamos ver A e B juntos.**
 - E o Teorema de *Bayes* simplesmente reorganiza isso para calcular o que queremos: **a chance de A, dado que B aconteceu.**

- Por que dividimos por $P(B)$?
 - Porque estamos ajustando a resposta para refletir **a realidade em que B já aconteceu**.
 - Pense assim:
 - Queremos saber, dentro de **todas as situações em que B aconteceu**, qual é a fração em que **A também aconteceu**. A divisão por $P(B)$ garante que estamos focando **apenas nas situações onde B ocorreu**, e recalculando as probabilidades com base nisso.
- Analogia simples:
 - Imagine que:
 - A: “choveu”;
 - B: “a grama está molhada”
 - Queremos saber: se a grama está molhada (B), qual a chance de que tenha chovido (A)?
 - Se só usarmos $P(A)$ e $P(B|A)$, podemos superestimar o papel da chuva;
 - Mas às vezes a grama molha por outro motivo (foi regada, por exemplo);
 - Então dividimos por $P(B)$ para levar em conta todas as causas possíveis para B — e assim obter uma estimativa mais realista para $P(A|B)$.

- Por que dividimos por $P(B)$?
 - **Porque estamos ajustando a resposta para refletir a realidade em que B já aconteceu.**
 - Pense assim:
 - Queremos saber, dentro de **todas as situações em que B aconteceu**, qual é a fração em que **A também aconteceu**. A divisão por $P(B)$ garante que estamos focando **apenas nas situações onde B ocorreu**, e recalculando as probabilidades com base nisso.
- Analogia simples:
 - Imagine que:
 - A: “choveu”;
 - B: “a grama está molhada”
 - Queremos saber: se a grama está molhada (B), qual a chance de que tenha chovido (A)?
 - Se só usarmos $P(A)$ e $P(B|A)$, podemos superestimar o papel da chuva;
 - Mas às vezes a grama molha por outro motivo (foi regada, por exemplo);
 - Então dividimos por $P(B)$ para levar em conta todas as causas possíveis para B — e assim obter uma estimativa mais realista para $P(A|B)$.

- Por que dividimos por $P(B)$?
 - Porque estamos ajustando a resposta para refletir **a realidade em que B já aconteceu**.
 - Pense assim:
 - **Queremos saber, dentro de todas as situações em que B aconteceu, qual é a fração em que A também aconteceu.** A divisão por $P(B)$ garante que estamos focando **apenas nas situações onde B ocorreu**, e recalculando as probabilidades com base nisso.
- Analogia simples:
 - Imagine que:
 - A: “choveu”;
 - B: “a grama está molhada”
 - Queremos saber: se a grama está molhada (B), qual a chance de que tenha chovido (A)?
 - Se só usarmos $P(A)$ e $P(B|A)$, podemos superestimar o papel da chuva;
 - Mas às vezes a grama molha por outro motivo (foi regada, por exemplo);
 - Então dividimos por $P(B)$ para levar em conta todas as causas possíveis para B — e assim obter uma estimativa mais realista para $P(A|B)$.

- Por que dividimos por $P(B)$?
 - Porque estamos ajustando a resposta para refletir **a realidade em que B já aconteceu**.
 - Pense assim:
 - Queremos saber, dentro de **todas as situações em que B aconteceu**, qual é a fração em que **A também aconteceu**. A divisão por $P(B)$ garante que estamos focando **apenas nas situações onde B ocorreu**, e recalculando as probabilidades com base nisso.
- Analogia simples:
 - Imagine que:
 - A: “choveu”;
 - B: “a grama está molhada”
 - Queremos saber: se a grama está molhada (B), qual a chance de que tenha chovido (A)?
 - Se só usarmos $P(A)$ e $P(B|A)$, podemos superestimar o papel da chuva;
 - Mas às vezes a grama molha por outro motivo (foi regada, por exemplo);
 - Então dividimos por $P(B)$ para levar em conta todas as causas possíveis para B — e assim obter uma estimativa mais realista para $P(A|B)$.

- Probabilidade de ter se ter uma doença com uma determinada idade.
- Em um hospital que atende pacientes com câncer, suponha que:
 - A probabilidade de um paciente ter câncer, independente da idade, é de 1%;
 - A probabilidade de um paciente ter 65 anos é de 0,2%;
 - Dentre os pacientes que têm câncer, a probabilidade de se ter 65 anos é de 0,5%.
- **Qual a probabilidade de um paciente ter câncer dado que ele tem 65 anos?**

- Definir os eventos e probabilidades:
 - $P(A)$: ?
 - $P(B)$: ?
 - $P(B|A)$: ?
 - $P(A|B)$: ?

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

- Definir os eventos e probabilidades:
 - **P(A)**: Probabilidade de se ter câncer = 1%;
 - **P(B)**: Probabilidade de se ter 65 anos = 0,2%;
 - **P(B|A)**: Probabilidade de ter 65 anos dado que se tem câncer = 0,5%;
 - **P(A|B)**: Probabilidade de ter câncer dado que ela tem 65 anos = ?

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

- Definir os eventos e probabilidades:
 - **P(A)**: Probabilidade de se ter câncer = 1%;
 - **P(B)**: Probabilidade de se ter 65 anos = 0,2%;
 - **P(B|A)**: Probabilidade de ter 65 anos dado que se tem câncer = 0,5%;
 - **P(A|B)**: Probabilidade de ter câncer dado que ela tem 65 anos = ?

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$P(\text{câncer}|65) = \frac{P(65|\text{câncer}) \times P(\text{câncer})}{P(65)} = \frac{0,5\% \times 1\%}{0,2\%} = \frac{0,005 \times 0,01}{0,002} = \frac{0,00005}{0,002} = 0,025 = 2,5\%$$

- Definir os eventos e probabilidades:
 - $P(A)$: Probabilidade de se ter câncer = 1%
 - $P(B)$: Probabilidade de se ter 65 anos = 0,2%
 - $P(B|A)$: Probabilidade de ter 65 anos d
 - $P(A|B)$: Probabilidade de ter câncer da

Interpretação (importante didaticamente)

- A probabilidade de câncer na população geral é 1%.
- Mas, condicionado a ter 65 anos, sobe para 2,5%.
- Isso faz sentido porque:
 - $P(B | A) > P(B)$, ou seja, pessoas com câncer são relativamente mais frequentes no grupo de 65 anos do que na população geral.

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$P(\text{câncer}|65) = \frac{P(65|\text{câncer}) \times P(\text{câncer})}{P(65)} = \frac{0,5\% \times 1\%}{0,2\%} = \frac{0,005 \times 0,01}{0,002} = \frac{0,00005}{0,002} = 0,025 = 2,5\%$$

Interpretação

- Se $P(B | A) > P(B)$:
 - Saber que A ocorreu **aumenta** a chance de B ;
 - Eventos são **positivamente dependentes**.
- Se $P(B | A) = P(B)$:
 - A **não afeta** B ;
 - Eventos são **independentes**.
- Se $P(B | A) < P(B)$:
 - Saber que A ocorreu **diminui** a chance de B ;
 - Eventos são **negativamente dependentes**.

- **Caso positivo:**
 - A : ter câncer;
 - B : ter 65 anos;
 - $P(B | A) > P(B) \rightarrow$ câncer mais comum em idosos.
- **Independência:**
 - A : jogar uma moeda dar cara;
 - B : chover amanhã;
 - $P(B | A) = P(B)$.
- **Dependência negativa**
 - A : passar em um concurso muito difícil;
 - B : não estudar;
 - $P(B | A) < P(B)$.

Classificador *Naïve Bayes*

- Considera que todos os atributos de um exemplos são independentes entre si:
 - Suposição ingênua;
 - Esse é o motivo do seu nome “*Naïve*”.
- Eventos independentes?
 - A ocorrência de um evento A em nada interfere na probabilidade de ocorrência do outro evento, B;
 - A probabilidade de ambos esses eventos independentes ocorrerem é igual ao produto de suas probabilidade.

Pulo do gato: Assume que todos os atributos são igualmente importantes e independentes.

- Considera que todos os atributos de um exemplos são independentes entre si:
 - Suposição ingênua;
 - Esse é o motivo do seu nome “*Naïve*”.
- Eventos independentes?
 - A ocorrência de um evento A em nada interfere na probabilidade de ocorrência do outro evento, B;
 - A probabilidade de ambos esses eventos independentes ocorrerem é igual ao produto de suas probabilidade.

Embora essa suposição seja otimista e não reflita 100% dos casos no mundo real, essa suposição facilita os cálculos.

Pulo do gato: Assume que todos os atributos são igualmente importantes e independentes.

- Considera que todos os atributos de um exemplos são independentes entre si:
 - Suposição ingênua;
 - Esse é o motivo do seu nome “*Naïve*”.
- Eventos independentes?
 - A ocorrência de um evento A em nada interfere na probabilidade de ocorrência do outro evento, B;
 - A probabilidade de ambos esses eventos independentes ocorrerem é igual ao produto de suas probabilidade.

Embora essa suposição seja otimista e não reflita 100% dos casos no mundo real, essa suposição facilita os cálculos.

Pulo do gato: Assume que todos os atributos são igualmente importantes e independentes.

- Considera que todos os atributos de um exemplos são independentes entre si:
 - Suposição ingênua;
 - Esse é o motivo do seu nome “*Naïve*”.
- Eventos independentes?
 - A ocorrência de um evento A em nada interfere na probabilidade de ocorrência do outro evento, B;
 - A probabilidade de ambos esses eventos independentes ocorrerem é igual ao produto de suas probabilidade.

Assumindo essa independência eu vou poder usar um produtório.

Embora essa suposição seja otimista e não reflita 100% dos casos no mundo real, essa suposição facilita os cálculos.

Pulo do gato: Assume que todos os atributos são igualmente importantes e independentes.


- Considera que todos os atributos de um exemplos são independentes entre si:
 - Suposição ingênua;
 - Esse é o motivo do seu nome “*Naïve*”.
- Eventos independentes?
 - A ocorrência de um evento A em nada interfere na probabilidade de ocorrência do outro evento, B;
 - A probabilidade de ambos os eventos independentes ocorrerem é igual ao produto de suas probabilidade.

- **A e B são independentes:**

- Não implica causalidade;
- Não implica “influência real”;
- Apenas diz que **saber A não muda a distribuição de B.**

Assumindo essa independência eu vou poder usar um produtório.

$$P(\textit{Corisa} = \textit{Sim}, \textit{Tosse} = \textit{Frequente}, \textit{Febre} = \textit{Alta}, \textit{Dor} = \textit{Garganta} | \textit{Gripe})$$


$$P(\textit{Corisa} = \textit{Sim} | \textit{Gripe}) \times P(\textit{Tosse} = \textit{Frequente} | \textit{Gripe}) \times \cdots \times P(\textit{Dor} = \textit{Garganta} | \textit{Gripe})$$

- Como adaptar isso para o problema de classificação?
 - Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
 - Seja Y um conjunto de classes com k classes, ou seja, $Y = \{y_1, y_2, y_3, \dots, y_k\}$.

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

- Como adaptar isso para o problema de classificação?
 - Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
 - Seja Y um conjunto de classes com k classes, ou seja, $Y = \{y_1, y_2, y_3, \dots, y_k\}$.

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$2. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

- Leitura correta:
 - A probabilidade de o exemplo pertencer à classe y_k , dado que observamos o vetor de atributos (exemplo) x_i ;
É proporcional a;
 - A **probabilidade de observar x_i assumindo que a classe é y_k , vezes a probabilidade da classe y_k ocorrer normalizada por $P(x_i)$.**
- Aqui estamos:
 - Fixando o exemplo x_i ;
 - Testando **todas as classes y_k .**

- Como adaptar isso para o problema de classificação?
 - Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
 - Seja Y um conjunto de classes com k classes, ou seja, $Y = \{y_1, y_2, y_3, \dots, y_k\}$.

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$2. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$3. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

- Como adaptar isso para o problema de classificação?

- Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
- Seja Y um conjunto de classes c

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$2. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$3. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$4. P(y_k|x_i) \propto P(x_i|y_k) \times P(y_k)$$

- Após remover $P(x_i)$, a equação já não é mais igualdade real:
 - Posso remover pois $P(x_i)$ é constante por não depender de y_k ;
 - $P(x_i)$ é uma função apenas de x_i , **não de** y_k .
- Quando eu uso $\propto$, você está dizendo:
 - Aqui não é mais igualdade, estamos ignorando uma constante — por isso usamos proporcionalidade.
- Estou comparando valores como:
 - Classe A: $\frac{0,01}{0,1} = 0,1$;
 - Classe B: $\frac{0,02}{0,1} = 0,2$.
- O denominador é o mesmo, portanto, não muda a ordem quando eu utilizar o *argmax* ou MAP.
- Importante:
 - Se você quer **a probabilidade exata**, então, **não pode remover** $P(x_i)$
 - Você remove **somente quando resolve um problema de decisão**: $\arg \max$

- Como adaptar isso para o problema de classificação?

- Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
- Seja Y um conjunto de classes c

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$2. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$3. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$4. P(y_k|x_i) \propto P(x_i|y_k) \times P(y_k)$$

- Após remover $P(x_i)$, a equação já não é mais igualdade real:
 - Posso remover pois $P(x_i)$ é constante por não depender de y_k ;
 - $P(x_i)$ é uma função apenas de x_i , **não de y_k** .
- Quando eu uso $\propto$, você está dizendo:
 - **Aqui não é mais igualdade, estamos ignorando uma constante — por isso usamos proporcionalidade.**
- Estou comparando valores como:
 - Classe A: $\frac{0,01}{0,1} = 0,1$;
 - Classe B: $\frac{0,02}{0,1} = 0,2$.
- O denominador é o mesmo, portanto, não muda a ordem quando eu utilizar o *argmax* ou MAP.
- Importante:
 - Se você quer **a probabilidade exata**, então, **não pode remover $P(x_i)$**
 - Você remove **somente quando resolve um problema de decisão**: $\arg \max$

- Como adaptar isso para o problema de classificação?

- Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
- Seja Y um conjunto de classes c

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$2. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$3. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$4. P(y_k|x_i) \propto P(x_i|y_k) \times P(y_k)$$

- Após remover $P(x_i)$, a equação já não é mais igualdade real
 - Posso remover pois $P(x_i)$ é constante por não depender de y_k ;
 - $P(x_i)$ é uma função apenas de x_i , **não de y_k** .
- Quando eu uso $\propto$, você está dizendo:
 - Aqui não é mais igualdade, estamos ignorando uma constante — por isso usamos proporcionalidade.
- Estou comparando valores como:
 - Classe A: $\frac{0,01}{0,1} = 0,1$;
 - Classe B: $\frac{0,02}{0,1} = 0,2$.
- O denominador é o mesmo, portanto, não muda a ordem quando eu utilizar o *argmax* ou MAP.
- **Importante:**
 - Se você quer **a probabilidade exata**, então, **não pode remover $P(x_i)$**
 - Você remove **somente quando resolve um problema de decisão: $\arg \max$**

- Como adaptar isso para o problema de classificação?
 - Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
 - Seja C um conjunto de classes com k classes, ou seja, $C = \{c_1, c_2, c_3, \dots, c_k\}$.

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$2. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$3. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$4. P(y_k|x_i) \propto P(x_i|y_k) \times P(y_k)$$

$$5. P(x_i|y_k) \propto \prod_{j=1}^m P(x_{ij}|y_k)$$

- A probabilidade de cada valor do atributo eu sei, porém, a probabilidade de observar o conjunto eu preciso do produtório.

- Leitura correta:
 - A probabilidade de observar todas as características do exemplo x_i , dado que ele pertence à classe y_k , é o produto das probabilidades de cada característica individual.
 - ou
 - A probabilidade do exemplo x_i dado a classe y_k é igual ao produto, para todos os atributos j , da probabilidade de o atributo j assumir o valor x_{ij} dado a classe y_k .

- Como adaptar isso para o problema de classificação?
 - Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
 - Seja C um conjunto de classes com k classes, ou seja, $C = \{c_1, c_2, c_3, \dots, c_k\}$.

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)} \quad 5. P(x_i|y_k) \propto \prod_{j=1}^m P(x_{ij}|y_k)$$

$$2. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$3. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{\cancel{P(x_i)}}$$

$$4. P(y_k|x_i) \propto P(x_i|y_k) \times P(y_k)$$

$$6. P(y_k|x_i) \propto P(y_k) \prod_{j=1}^m P(x_{ij}|y_k) = P(y_k) \times P(x_{i1}|y_k) \times P(x_{i2}|y_k) \times \dots \times P(x_{im}|y_k)$$

- Como adaptar isso para o problema de classificação?
 - Seja X um exemplo descrito por m atributos, ou seja, $X = \{x_1, x_2, x_3, \dots, x_m\}$;
 - Seja C um conjunto de classes com k classes, ou seja, $C = \{c_1, c_2, c_3, \dots, c_k\}$.

$$1. P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$5. P(x_i|y_k) \propto \prod_{j=1}^m P(x_{ij}|y_k)$$

$$2. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$6. P(y_k|x_i) \propto P(y_k) \prod_{j=1}^m P(x_{ij}|y_k) = P(y_k) \times P(x_{i1}|y_k) \times P(x_{i2}|y_k) \times \dots \times P(x_{im}|y_k)$$

$$3. P(y_k|x_i) = \frac{P(x_i|y_k) \times P(y_k)}{P(x_i)}$$

$$4. P(y_k|x_i) \propto P(x_i|y_k) \times P(y_k)$$

$$7. P(y_k|x_i) \propto P(y_k) \prod_{j=1}^m P(x_{ij}|y_k)$$

- Assume que todos os valores dos atributos de um exemplo são independentes entre si.
- A ocorrência do evento A em nada interfere na probabilidade de ocorrência de outro exemplo, B.

$$P(y_k | x_i) \propto P(y_k) \prod_{j=1}^m P(x_{ij} | y_k)$$

- Assume que todos os valores dos atributos de um exemplo são independentes entre si.
- A ocorrência do evento A em nada interfere na probabilidade de ocorrência de outro exemplo, B.

$$P(y_k | x_i) \propto P(y_k) \prod_{j=1}^m P(x_{ij} | y_k)$$

Probabilidade de ocorrer o valor do j -ésimo atributo, dada a ocorrência da k -ésima classe.

- Assume que todos os valores dos atributos de um exemplo são independentes entre si.
- A ocorrência do evento A em nada interfere na probabilidade de ocorrência de outro exemplo, B.

Probabilidade (a priori) da k -ésima classe no conjunto de dados.

$$P(y_k | x_i) \propto P(y_k) \prod_{j=1}^m P(x_{ij} | y_k)$$

Probabilidade de ocorrer o valor do j -ésimo atributo, dada a ocorrência da k -ésima classe.

- Assume que todos os valores dos atributos de um exemplo são independentes entre si.
- A ocorrência do evento A em nada interfere na probabilidade de ocorrência de outro exemplo, B.

Probabilidade (a priori) da k -ésima classe no conjunto de dados.

$$P(y_k | x_i) \propto P(y_k) \prod_{j=1}^m P(x_{ij} | y_k)$$

Probabilidade de ocorrer o valor do j -ésimo atributo, dada a ocorrência da k -ésima classe.

Qual é a probabilidade dos valores dos atributos de x_i corresponderem à k -ésima classe (y_k)?

- Dado que X é nosso conjunto de treinamento e $Y = \{y_1, y_2, \dots, y_k\}$ o conjunto de classes com k classes
- A probabilidade a priori de ocorrer a classe y_i é dado por:

$$P(y_i) = \frac{|y_i|}{|X|}$$

na qual $|y_i|$ é o número de exemplos de treinamento das classes y_i em X e $|X|$ é o número de exemplos em todo o conjunto.

- Após o cálculo da probabilidades a posteriori para todas as classe, pode-se selecionar a classe com maior valor de probabilidade
- Esse método é denominado Estimativa por MAP (do inglês, *Maximum a Posteriori*).

$$\mathbf{MAP}(\mathbf{x}_i) = \hat{\mathbf{y}}(\mathbf{x}_i) = \operatorname{agmax}_{y \in Y} \left(P(y) \prod_{j=1}^m P(x_{ij}|y) \right)$$

- Se tivermos o mesmo número de observações em cada classe nos dados de treinamento a probabilidade de cada classe $P(y_k)$ será igual, portanto, $P(y_k)$ seria um termo constante a equação e pode ser omitido.

$$\text{MAP}(x_i) = \hat{y}(x_i) = \underset{y \in Y}{\text{argmax}} \left(\prod_{j=1}^m P(x_{ij}|y) \right)$$

- Podemos aplicar *log* nas probabilidades.
- Facilitar o cálculo das probabilidades, gerando cálculos mais simples.
- O *log* de um produto passa a ser uma soma de *logs*.
- Evita que probabilidades pequenas sejam multiplicadas entre si gerando valores menores ainda.

$$\log P(\mathbf{y}_k | \mathbf{x}_i) \propto \log \left[P(\mathbf{y}_k) \prod_{j=1}^m P(x_{ij} | \mathbf{y}_k) \right]$$

$$\log P(\mathbf{y}_k | \mathbf{x}_i) \propto \log P(\mathbf{y}_k) + \sum_{j=1}^m \log P(x_{ij} | \mathbf{y}_k)$$

- *Insight* forte (nível mais profundo):

- O que você está fazendo é:

- Trabalhando com **distribuição não normalizada**:

$$\tilde{P}(y_k | x_i) = P(x_i | y_k)P(y_k)$$

- Mas depois podemos (se quiser):

$$P(y_k | x_i) = \frac{\tilde{P}(y_k | x_i)}{\sum_k \tilde{P}(y_k | x_i)}$$

Furta	Longa	Doce	Amarela
Banana	Sim	Sim	Não
Laranja	Não	Sim	Não
Banana	Sim	Não	Sim
Pera	Não	Sim	Não
Banana	Não	Sim	Sim
....	...	...	...

- Temos dados sobre 1000 pedaços de frutas:
 - Banana , Laranja e Pera.
- Sabemos 3 características sobre cada fruta:
 - Longa, doce e amarela.

Tabela de contagens

Furta	Longa	Não Longa	Total	Doce	Não Doce	Total	Amarela	Não Amarela	Total
Banana	400	100	500	350	150	500	450	50	500
Laranja	0	300	300	150	150	300	300	0	300
Outra Fruta	100	100	200	150	50	200	50	150	200
Total	500	500	1000	650	350	1000	800	200	1000

- Probabilidades a priori das classes:
 - $P(\text{Banana}) = 500 / 1000 = 0.5$;
 - $P(\text{Laranja}) = 300 / 1000 = 0.3$;
 - $P(\text{Pera}) = 200 / 1000 = 0.2$.

Furta	Longa	Não Longa	Total	Doce	Não Doce	Total	Amarela	Não Amarela	Total
Banana	400	100	500	350	150	500	450	50	500
Laranja	0	300	300	150	150	300	300	0	300
Outra Fruta	100	100	200	150	50	200	50	150	200
Total	500	500	1000	650	350	1000	800	200	1000

- Probabilidades a priori das classes:
 - $P(\text{Banana}) = 500 / 1000 = 0.5$;
 - $P(\text{Laranja}) = 300 / 1000 = 0.3$;
 - $P(\text{Pera}) = 200 / 1000 = 0.2$.
- Probabilidades a priori das evidências:
 - $P(\text{Longa}) = 500 / 1000 = 0.5$;
 - $P(\text{Doce}) = 650 / 1000 = 0.65$;
 - $P(\text{Amarela}) = 800 / 1000 = 0.8$.

Fruta	Longa	Não Longa	Total	Doce	Não Doce	Total	Amarela	Não Amarela	Total
Banana	400	100	500	350	150	500	450	50	500
Laranja	0	300	300	150	150	300	300	0	300
Outra Fruta	100	100	200	150	50	200	50	150	200
Total	500	500	1000	650	350	1000	800	200	1000

- Probabilidades a priori das classes:
 - $P(\text{Banana}) = 500 / 1000 = 0.5$;
 - $P(\text{Laranja}) = 300 / 1000 = 0.3$;
 - $P(\text{Pera}) = 200 / 1000 = 0.2$.
- Probabilidades a priori das evidências:
 - $P(\text{Longa}) = 500 / 1000 = 0.5$;
 - $P(\text{Doce}) = 650 / 1000 = 0.65$;
 - $P(\text{Amarela}) = 800 / 1000 = 0.8$.

- Probabilidades de verossimilhança:
 - $P(\text{Longa} | \text{Banana}) = 400 / 500 = 0.8$;
 - $P(\text{Não Longa} | \text{Banana}) = 100 / 500 = 0.2$;
 - ...
 - ...
 - ...
 - $P(\text{Amarelo} | \text{Pera}) = 50 / 200 = 0.25$;
 - $P(\text{Não Amarelo} | \text{Pera}) = 150 / 200 = 0.75$.

Fruta	Longa	Não Longa	Total	Doce	Não Doce	Total	Amarela	Não Amarela	Total
Banana	400	100	500	350	150	500	450	50	500
Laranja	0	300	300	150	150	300	300	0	300
Outra Fruta	100	100	200	150	50	200	50	150	200
Total	500	500	1000	650	350	1000	800	200	1000

- Probabilidades a priori das classes:
 - $P(\text{Banana}) = 500 / 1000 = 0.5$;
 - $P(\text{Laranja}) = 300 / 1000 = 0.3$;
 - $P(\text{Pera}) = 200 / 1000 = 0.2$.
- Probabilidades a priori das evidências:
 - $p(\text{Longa}) = 500 / 1000 = 0.5$;
 - $P(\text{Doce}) = 650 / 1000 = 0.65$;
 - $P(\text{Amarela}) = 800 / 1000 = 0.8$.
- Probabilidades de verossimilhança:
 - $P(\text{Longa} | \text{Banana}) = 400 / 500 = 0.8$;
 - $P(\text{Não Longa} | \text{Banana}) = 100 / 500 = 0,2$;
 - $P(\text{Longa} | \text{Laranja}) = 0 / 300 = 0$;
 - $P(\text{Não Longa} | \text{Laranja}) = 300 / 300 = 1,0$;
 - $P(\text{Longa} | \text{Pera}) = 100 / 200 = 0,5$.

- ...
 - $P(\text{Não Longa} | \text{Pera}) = 100 / 200 = 0,5$;
 - $P(\text{Doce} | \text{Banana}) = 350 / 500 = 0,7$;
 - $P(\text{Não Doce} | \text{Banana}) = 150 / 500 = 0,428$;
 - $P(\text{Doce} | \text{Laranja}) = 150 / 300 = 0,5$;
 - $P(\text{Não Doce} | \text{Laranja}) = 150 / 300 = 0,5$;
 - $P(\text{Doce} | \text{Pera}) = 150 / 200 = 0,75$;
 - $P(\text{Não Doce} | \text{Pera}) = 50 / 200 = 0,25$;
 - $P(\text{Amarelo} | \text{Banana}) = 450 / 500 = 0,9$;
 - $P(\text{Não Amarelo} | \text{Banana}) = 50 / 500 = 0,9$;
 - $P(\text{Amarelo} | \text{Laranja}) = 300 / 300 = 1,0$;
 - $P(\text{Não Amarelo} | \text{Laranja}) = 0 / 300 = 0$;
 - $P(\text{Amarelo} | \text{Pera}) = 50 / 200 = 0,25$;
 - $P(\text{Não Amarelo} | \text{Pera}) = 150 / 200 = 0,75$.

- Dado um fruto, como classificá-lo?
- Novo exemplo $x_i = \{\textit{Longa}, \textit{Doce}, \textit{Amarela}\}$.



$$P(\textit{Banana}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Banana}) \times P(\textit{Longa}|\textit{Banana}) \times P(\textit{Doce}|\textit{Banana}) \times P(\textit{Amarela}|\textit{Banana})$$



$$P(\textit{Laranja}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Laranja}) \times P(\textit{Longa}|\textit{Laranja}) \times P(\textit{Doce}|\textit{Laranja}) \times P(\textit{Amarela}|\textit{Laranja})$$



$$P(\textit{Pera}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Pera}) \times P(\textit{Longa}|\textit{Pera}) \times P(\textit{Doce}|\textit{Pera}) \times P(\textit{Amarela}|\textit{Pera})$$

- Dado um fruto, como classificá-lo?
- Novo exemplo $\mathbf{x}_i = \{\textit{Longa}, \textit{Doce}, \textit{Amarela}\}$.



$$P(\textit{Banana}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Banana}) \times P(\textit{Longa}|\textit{Banana}) \times P(\textit{Doce}|\textit{Banana}) \times P(\textit{Amarela}|\textit{Banana})$$

$$P(\textit{Banana}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = 0,5 \times 0,8 \times 0,7 \times 0,9 = 0,252$$



$$P(\textit{Laranja}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Laranja}) \times P(\textit{Longa}|\textit{Laranja}) \times P(\textit{Doce}|\textit{Laranja}) \times P(\textit{Amarela}|\textit{Laranja})$$

$$P(\textit{Laranja}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = 0,3 \times 0 \times 0,5 \times 1,0 = 0,0$$

Opa!!! o que é isso?



$$P(\textit{Pera}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Pera}) \times P(\textit{Longa}|\textit{Pera}) \times P(\textit{Doce}|\textit{Pera}) \times P(\textit{Amarela}|\textit{Pera})$$

$$P(\textit{Pera}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = 0,2 \times 0,5 \times 0,75 \times 0,25 = 0,01875$$

- Dado um fruto, como classificá-lo?
- Novo exemplo $\mathbf{x}_i = \{\textit{Longa}, \textit{Doce}, \textit{Amarela}\}$.



$$P(\textit{Banana}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Banana}) \times P(\textit{Longa}|\textit{Banana}) \times P(\textit{Doce}|\textit{Banana}) \times P(\textit{Amarela}|\textit{Banana})$$

$$P(\textit{Banana}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = 0,5 \times 0,8 \times 0,7 \times 0,9 = 0,252$$



$$P(\textit{Laranja}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Laranja}) \times P(\textit{Longa}|\textit{Laranja}) \times P(\textit{Doce}|\textit{Laranja}) \times P(\textit{Amarela}|\textit{Laranja})$$

$$P(\textit{Laranja}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = 0,3 \times 0 \times 0,5 \times 1,0 = 0,0$$



$$P(\textit{Pera}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = P(\textit{Pera}) \times P(\textit{Longa}|\textit{Pera}) \times P(\textit{Doce}|\textit{Pera}) \times P(\textit{Amarela}|\textit{Pera})$$

$$P(\textit{Pera}|\textit{Longa}, \textit{Doce} \text{ e } \textit{Amarela}) = 0,2 \times 0,5 \times 0,75 \times 0,25 = 0,01875$$

ID	Tempo	Temperatura	Umidade	Vento	Classe
1	Ensolarado	Média	Baixa	Sim	Joga
2	Ensolarado	Alta	Alta	Sim	Não Joga
3	Ensolarado	Alta	Média	Não	Não Joga
4	Ensolarado	Média	Alta	Não	Não Joga
5	Ensolarado	Média	Baixa	Não	Joga
6	Nublado	Média	Alta	Sim	Joga
7	Nublado	Alta	Média	Não	Joga
8	Nublado	Baixa	Baixa	Sim	Joga
9	Nublado	Alta	Alta	Não	Joga
10	Chuvoso	Média	Média	Sim	Não Joga
11	Chuvoso	Média	Baixa	Sim	Não Joga
12	Chuvoso	Média	Média	Não	Joga
13	Chuvoso	Alta	Média	Não	Joga
14	Chuvoso	Média	Alta	Não	Joga

Naïve Bayes

Exemplo: Jogar Tênis

ID	Tempo	Temperatura	Umidade	Vento	Classe	c_i	$c_1 = \text{Joga}$	$c_2 = \text{Não Joga}$
1	Ensolarado	Média	Baixa	Sim	Joga	$P(y_k)$	$9/14 = 0.64$	$5/14 = 0.36$
2	Ensolarado	Alta	Alta	Sim	Não Joga	$P(\text{Tempo}=\text{Ensolarado} \mid y_k)$	$2/9 = 0.22$	$3/5 = 0.6$
3	Ensolarado	Alta	Média	Não	Não Joga	$P(\text{Tempo}=\text{Nublado} \mid y_k)$	$4/9 = 0.45$	$0/5 = 0.03^*$
4	Ensolarado	Média	Alta	Não	Não Joga	$P(\text{Tempo}=\text{Chuvoso} \mid y_k)$	$3/9 = 0.33$	$2/5 = 0.4$
5	Ensolarado	Média	Baixa	Não	Joga	$P(\text{Temperatura}=\text{Baixa} \mid y_k)$	$1/9 = 0.11$	$0/5 = 0.03^*$
6	Nublado	Média	Alta	Sim	Joga	$P(\text{Temperatura}=\text{Média} \mid y_k)$	$6/9 = 0.67$	$3/5 = 0.6$
7	Nublado	Alta	Média	Não	Joga	$P(\text{Temperatura}=\text{Alta} \mid y_k)$	$2/9 = 0.22$	$2/5 = 0.4$
8	Nublado	Baixa	Baixa	Sim	Joga	$P(\text{Umidade}=\text{Baixa} \mid y_k)$	$3/9 = 0.33$	$1/5 = 0.2$
9	Nublado	Alta	Alta	Não	Joga	$P(\text{Umidade}=\text{Média} \mid y_k)$	$4/9 = 0.45$	$2/5 = 0.4$
10	Chuvoso	Média	Média	Sim	Não Joga	$P(\text{Umidade}=\text{Alta} \mid y_k)$	$2/9 = 0.22$	$2/5 = 0.4$
11	Chuvoso	Média	Baixa	Sim	Não Joga	$P(\text{Vento}=\text{Sim} \mid y_k)$	$3/9 = 0.33$	$3/5 = 0.6$
12	Chuvoso	Média	Média	Não	Joga	$P(\text{Vento}=\text{Não} \mid y_k)$	$6/9 = 0.67$	$2/5 = 0.4$
13	Chuvoso	Alta	Média	Não	Joga	* Valores nulos são substituídos por 0,03.		
14	Chuvoso	Média	Alta	Não	Joga			

- Dado um novo exemplo, como classificá-lo?
- Novo exemplo $x_i = \{\mathbf{Chuva}, \mathbf{Baixa}, \mathbf{Baixa}, \mathbf{Nao}\}$.



$$P(y_1|x_i) = P(y_1|Tempo = Chuva) \times P(y_1|Temperatura = Baixa) \times P(y_1|Umidade = Baixa) \times P(y_1|Vento = Sim) \times P(y_1)$$



$$P(y_2|x_i) = P(y_2|Tempo = Chuva) \times P(y_2|Temperatura = Baixa) \times P(y_2|Umidade = Baixa) \times P(y_2|Vento = Sim) \times P(y_2)$$

- Dado um novo exemplo, como classificá-lo?
- Novo exemplo $x_i = \{\mathbf{Chuva}, \mathbf{Baixa}, \mathbf{Baixa}, \mathbf{Nao}\}$.


$$P(y_1|x_i) = P(y_1|Tempo = Chuva) \times P(y_1|Temperatura = Baixa) \times P(y_1|Umidade = Baixa) \times P(y_1|Vento = Sim) \times P(y_1)$$
$$P(y_1|x_i) = 0,33 \times 0,11 \times 0,33 \times 0,67 \times 0,64 = 0,0051365$$


$$P(y_2|x_i) = P(y_2|Tempo = Chuva) \times P(y_2|Temperatura = Baixa) \times P(y_2|Umidade = Baixa) \times P(y_2|Vento = Sim) \times P(y_2)$$
$$P(y_2|x_i) = 0,4 \times 0,03 \times 0,2 \times 0,4 \times 0,36 = 0,0003456$$

- Dado um novo exemplo, como classificá-lo?
- Novo exemplo $x_i = \{\mathbf{Chuva}, \mathbf{Baixa}, \mathbf{Baixa}, \mathbf{Nao}\}$.

 $P(y_1|x_i) = P(y_1|Tempo = Chuva) \times P(y_1|Temperatura = Baixa) \times P(y_1|Umidade = Baixa) \times P(y_1|Vento = Sim) \times P(y_1)$
 $P(y_1|x_i) = 0,33 \times 0,11 \times 0,33 \times 0,67 \times 0,64 = 0,0051365$

 $P(y_2|x_i) = P(y_2|Tempo = Chuva) \times P(y_2|Temperatura = Baixa) \times P(y_2|Umidade = Baixa) \times P(y_2|Vento = Sim) \times P(y_2)$
 $P(y_2|x_i) = 0,4 \times 0,03 \times 0,2 \times 0,4 \times 0,36 = 0,0003456$

Problema da frequência zero

- Frequência Zero:
 - Se não foi encontrada nenhuma ocorrência do valor de um atributo para uma classe, a probabilidade será 0;
 - A probabilidade igual a 0 cancela o efeito de outras probabilidades envolvidas no cálculo da probabilidade de um exemplo x_i pertencer a classe y_k .

y_k	$y_1 = \text{Joga}$	$y_2 = \text{Não Joga}$
$P(y_k)$	$9/14 = 0,64$	$5/14 = 0,36$
$P(\text{Tempo}=\text{Ensolarado} \mid y_k)$	$2/9 = 0,22$	$3/5 = 0,6$
$P(\text{Tempo}=\text{Nublado} \mid y_k)$	$4/9 = 0,45$	$0/5 = 0$
$P(\text{Tempo}=\text{Chuvoso} \mid y_k)$	$3/9 = 0,33$	$2/5 = 0,4$
$P(\text{Temperatura}=\text{Baixa} \mid y_k)$	$1/9 = 0,11$	$0/5 = 0$
$P(\text{Temperatura}=\text{Média} \mid y_k)$	$6/9 = 0,67$	$3/5 = 0,6$
...	...	...

- Estimador Laplace:
 - Adicionar um exemplo fictício para cada valor de um atributo para cada uma das classes;
 - Considere o atributo “Tempo” do conjunto de dados “Jogar Tênis”, na qual a frequência do valor “Nublado” para a classe “Não Jogar” é 0;
 - Dado o Estimador de Laplace, as novas probabilidades para o valor “Nublado” para a classe “Não Jogar” são:

$$P(\text{Tempo} = \text{Ensolarado} \mid y_k) = \frac{3}{5} = \frac{3 + 1}{5 + 3}$$

$$P(\text{Tempo} = \text{Nublado} \mid y_k) = \frac{0}{5} = \frac{0 + 1}{5 + 3}$$

$$P(\text{Tempo} = \text{Chuvoso} \mid y_k) = \frac{2}{5} = \frac{2 + 1}{5 + 3}$$

- Estimador Laplace:
 - Adicionar um exemplo fictício para cada valor de um atributo para cada uma das classes;
 - Considere o atributo “Tempo” do conjunto de dados “Jogar Tênis”, na qual a frequência do valor “Nublado” para a classe “Não Jogar” é 0;
 - Dado o Estimador de Laplace, as novas probabilidades para o valor “Nublado” para a classe “Não Jogar” são:

$$P(\text{Tempo} = \text{Ensolarado} \mid y_k) = \frac{3}{5} = \frac{3 + 1}{5 + 3}$$

$$P(\text{Tempo} = \text{Nublado} \mid y_k) = \frac{0}{5} = \frac{0 + 1}{5 + 3}$$

Como são 3 instancias a mais, eu devo somar 3 no denominador.

$$P(\text{Tempo} = \text{Chuvoso} \mid y_k) = \frac{2}{5} = \frac{2 + 1}{5 + 3}$$

- Estimador Laplace:
 - Adicionar um exemplo fictício para cada valor de um atributo para cada uma das classes;
 - Considere o atributo “Tempo” do conjunto de dados “Jogar Tênis”, na qual a frequência do valor “Nublado” para a classe “Não Jogar” é 0;
 - Dado o Estimador de Laplace, as novas probabilidades para o valor “Nublado” para a classe “Não Jogar” são:

$$P(\text{Tempo} = \text{Ensolarado} \mid y_k) = \frac{3}{5} = \frac{3 + 1}{5 + 3}$$

$$P(\text{Tempo} = \text{Nublado} \mid y_k) = \frac{0}{5} = \frac{0 + 1}{5 + 3}$$

$$P(\text{Tempo} = \text{Chuvoso} \mid y_k) = \frac{2}{5} = \frac{2 + 1}{5 + 3}$$

Este procedimento deve ser realizado para todas as classes, ou seja, devemos estender esse procedimento para a classe “Sim”.

- Estimativa m :
 - Adicionar múltiplas unidades fictícias para cada valor de um atributo para cada uma das classes:

$$P(x_i | y_k) = \frac{N_{y_k} + m\rho}{N + m}$$

na qual N é o número total de exemplos da classe y_k , N_{y_k} é o número de exemplos de treinamento da classe y_k que possuem o valor x_i , m é o tamanho do conjunto de exemplos fictícios e ρ é um parâmetro definido pelo usuário e define um peso para aos valores fictícios.

- Considere o atributo “Tempo” do conjunto de dados “Jogar Tênis”, na qual a frequência do valor “Nublado” para a classe “Não Jogar” é 0.
- Dado o Estimador de m e $\rho = \frac{1}{3}$, as novas probabilidades para o valor “Nublado” para a classe “Não” são:

$$P(\text{Tempo} = \text{Ensolarado} \mid y_k) = \frac{3}{5} = \frac{3 + \frac{m}{3}}{5 + m}$$

$$P(\text{Tempo} = \text{Nublado} \mid y_k) = \frac{0}{5} = \frac{0 + \frac{m}{3}}{5 + m}$$

$$P(\text{Tempo} = \text{Chuvoso} \mid y_k) = \frac{2}{5} = \frac{2 + \frac{m}{3}}{5 + m}$$

- Considere o atributo “Tempo” do conjunto de dados “Jogar Tênis”, na qual a frequência do valor “Nublado” para a classe “Não Jogar” é 0.
- Dado o Estimador de m e $\rho = \frac{1}{3}$, as novas probabilidades para o valor “Nublado” para a classe “Não” são:

$$P(\text{Tempo} = \text{Ensolarado} \mid y_k) = \frac{3}{5} = \frac{3 + \frac{m}{3}}{5 + m}$$

$$P(\text{Tempo} = \text{Nublado} \mid y_k) = \frac{0}{5} = \frac{0 + \frac{m}{3}}{5 + m}$$

$$P(\text{Tempo} = \text{Chuvoso} \mid y_k) = \frac{2}{5} = \frac{2 + \frac{m}{3}}{5 + m}$$

Este procedimento deve ser realizado para todas as classes, ou seja, devemos estender esse procedimento para a classe “Sim”.

Valores ausentes

- Se um exemplo de teste possui um valor ausente, este deve ser omitido do cálculo da probabilidade.
- Se um exemplo de treinamento possui um valor ausente, este simplesmente não é incluído no cálculo das frequências.
- Ou podemos imputar valores faltantes na etapa de pré-processamento.

ID	Tempo	Temperatura	Umidade	Vento	Classe
1	Ensolarado	Média	Baixa	Sim	Joga
2	Ensolarado	-	Alta	Sim	Não Joga
3	Ensolarado	Alta	Média	Não	Não Joga
4	Ensolarado	Média	-	Não	Não Joga
5	-	Média	Baixa	Não	Joga
6	Nublado	Média	Alta	Sim	Joga
7	...	...	...	...	...

Valores contínuos


- **Importante:**
 - $P(\cdot) \rightarrow$ variável discreta (classe);
 - $p(\cdot) \rightarrow$ variável contínua (atributos).
 - Isso é **normal em ML**
- **Naive Bayes contínuo (Gaussiano):**
 - A hipótese de independência vira:

$$p(x_i | y_k) = \prod_{j=1}^m p(x_{ij} | y_k)$$

- Se o atributo i é contínuo, tipicamente assume-se uma distribuição gaussiana (distribuição normal) com média μ e desvio padrão σ definida por:


$$p(x_{ij} | y_k) = \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} \exp\left(-\frac{(x_{ij} - \mu_{ij})^2}{2\sigma_{ij}^2}\right)$$

- Gaussiana ou distribuição normal.
- **O significado das áreas:**
 - As áreas sombreadas representam **probabilidades**:
 - **Regra empírica:**
 - **68% dos dados** estão entre:
 - $\mu - \sigma$ e $\mu + \sigma$.
 - **95% dos dados** estão entre:
 - $\mu - 2\sigma$ e $\mu + 2\sigma$.
 - **99.7% dos dados** estão entre:
 - $\mu - 3\sigma$ e $\mu + 3\sigma$.
 - **Intuição importante:**
 - Quanto mais longe da média, **menos provável** é o valor:
 - Valores perto de μ : muito comuns;
 - Valores longe: raros;
 - Valores além de 3σ : extremamente raros.




Fonte: <https://www.inf.ufsc.br/~andre.zibetti/probabilidade/normal.html>


- Conjunto de dados contendo Gafanhotos e Esperança e atributos numéricos.



- Conjunto de dados contendo Gafanhotos e Esperança e atributos numéricos.



- Conjunto de dados contendo Gafanhotos e Esperança e atributos numéricos.



- Prever se o dia será “Ensolarado” ou “Nublado” com base em:
 - Temperatura (°C);
 - Umidade (%).
 - Embora sejam valores contínuos, nesse exemplo, vou arredondar os números para facilitar os códigos.

Temperatura	Umidade	Classe
30	80	Ensolarado
28	85	Ensolarado
35	75	Ensolarado
20	65	Nublado
18	70	Nublado
22	60	Nublado

Temperatura	Umidade	Classe
30	80	Ensolarado
28	85	Ensolarado
35	75	Ensolarado
20	65	Nublado
18	70	Nublado
22	60	Nublado

1. Calcular P(classe):

- Ensolarado: 3 exemplos;
- Nublado: 3 exemplos.

$$P(\text{Ensolarado}) = 0.5$$

$$P(\text{Nublado}) = 0.5$$

2. Calcular média e desvio padrão para cada atributo por classe:

• **Classe Ensolarado:**

• **Temperatura: (30, 28, 35);**

$$\mu = \frac{30 + 28 + 35}{3} = 31$$

$$\sigma = \sqrt{\left[\frac{1^2 + 3^2 + 4^2}{3} \right]} = \sqrt{\frac{26}{3}} = 2.94$$

• **Umidade: (80, 85, 75);**

$$\mu = \frac{80 + 85 + 75}{3} = 80$$

$$\sigma = \sqrt{\left[\frac{0^2 + 5^2 + 5^2}{3} \right]} = \sqrt{\frac{50}{3}} = 4.08$$

• **Classe Nublado:**

• **Temperatura: (20, 18, 22);**

$$\mu = \frac{20 + 18 + 22}{3} = 20$$

$$\sigma = \sqrt{\left[\frac{0^2 + 2^2 + 2^2}{3} \right]} = \sqrt{\frac{8}{3}} = 1.63$$

• **Umidade: (65, 70, 60);**

$$\mu = \frac{65, 70, 60}{3} = 65$$

$$\sigma = \sqrt{\left[\frac{0^2 + 5^2 + 5^2}{3} \right]} = \sqrt{\frac{50}{3}} = 4.08$$

3. Nova amostra a classificar:

- Temperatura = 21;
- Umidade = 66.

4. Calcular $P(x_i|y_k)$ para cada atributo com Gaussiana:

$$p(x_{ij} | y_k) = \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} \exp\left(-\frac{(x_{ij} - \mu_{ij})^2}{2\sigma_{ij}^2}\right)$$

- **Classe Ensolarado:**

$P(21|Ens - tempo)$

$\mu = 31$ e $\sigma = 2.94 \Rightarrow \approx 0.0004$

$P(66|Ens - umid)$

$\mu = 80$ e $\sigma = 4.08 \Rightarrow (66 - 80)^2 = 196 \Rightarrow e^{-196/2 \times 16.6} \approx e^{-5.9} \approx 0.0027 \Rightarrow P \approx \frac{1}{\sqrt{2\pi \times 16.6}} \times 0.0027 \approx \frac{1}{10.2} \times 0.0027 \approx 0.00026$

$Score_{Ensolarado} = 0.5 \times 0.0004 \times 0.00026 \approx 5.2 \times 10^{-8}$

3. Nova amostra a classificar:

- Temperatura = 21;
- Umidade = 66.

4. Calcular $P(x_i|y_k)$ para cada atributo com Gaussiana:

$$p(x_{ij} | y_k) = \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} \exp\left(-\frac{(x_{ij} - \mu_{ij})^2}{2\sigma_{ij}^2}\right)$$

- Classe Nublado:

$P(21|Nublado - tempo)$

$$\mu = 20 \text{ e } \sigma = 1.63 \Rightarrow (21 - 20)^2 = 1 \Rightarrow e^{-1/5.32} \approx 0.829 \Rightarrow P \approx 0.245 \times 0.829 \approx 0.203$$

$P(66|Nublado - umid)$

$$\mu = 65 \text{ e } \sigma = 4.08 \Rightarrow (66 - 65)^2 = 1 \Rightarrow e^{-1/33.2} \approx 0.97 \Rightarrow P \approx \frac{1}{10.2} \times 0.97 \approx 0.095$$

$$\text{Score Nublado} = 0.5 \times 0.203 \times 0.095 \approx 0.0096$$

3. Nova amostra a classificar:

- Temperatura = 21;
- Umidade = 66.

4. Calcular $P(x_i|y_k)$ para cada atributo com Gaussiana:

$$p(x_{ij} | y_k) = \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} \exp\left(-\frac{(x_{ij} - \mu_{ij})^2}{2\sigma_{ij}^2}\right)$$

- Classe Nublado:

Score Nublado ≈ 0.0096





- Classe Ensolarado:


Score Ensolarado $\approx 5.2 \times 10^{-8}$

- Logo, o classificador prediz que o dia será:
 - Nublado


- Usando o Python para plotar os dados em 2D:





- Usando o Python para plotar os dados em 2D:




Qual a maior probabilidade?




- Usando o Python para plotar os dados em 3D:



- Usando o Python para plotar *scatter plot* com distribuições marginais (*marginal plot*):





- Por que a probabilidade final é pequena mesmo estando perto do “cume” das distribuições?
 - 0.0096?



- Cada $P(x_i|y_k)$ é uma densidade, não uma probabilidade comum:
 - Quando usamos a distribuição Gaussiana, o que obtemos da gaussiana não é uma “probabilidade” no sentido clássico (como 0.7, 0.2, etc), mas sim uma **densidade de probabilidade**, que **pode ser menor que 1** mesmo nos picos!
 - Isso é normal.
 - As densidades podem facilmente ser algo como 0.3, 0.05, 0.01, etc.
- Resumo:
 - O valor “baixo” da probabilidade **não indica erro**;
 - Isso acontece porque estamos lidando com **densidades contínuas**, e não com probabilidades brutas;
 - O mais importante no *Naive Bayes* é **comparar os valores entre as classes**, não o valor absoluto;
 - Mesmo uma densidade baixa pode indicar uma boa classificação se ela for **maior do que a das outras classes**.

<https://planetcalc.com/4986/>

- Outras distribuições?
- Discretizar os atributos



Considerações finais

- Vantagens:
 - ...
 - ...
 - ...
 - ...
- Desvantagens:
 - ...
 - ...

- Vantagens:
 - Abordagem simples;
 - Rápido;
 - Robusto a ruídos e atributos irrelevantes;
 - Relativamente interpretável.
- Desvantagens:
 - Atributos redundantes podem prejudicar a classificação;
 - Atributos numéricos?

Próxima aula

- Validação de algoritmos

Obrigado



Dúvidas

Email: alanvalejo@ufscar.br

Acessar o fórum no Moodle

Comparecer ao plantão de dúvidas